时空深度学习模型在玉米—大豆分类中的空间泛化能力分析

黄游缘[1]，林 娜[1]，范 莉[2]

（1. 重庆交通大学智慧城市学院，重庆 400074；2. 中国气象局气候资源经济转化重点开放实验室重庆市气象服务中心，重庆 401147）

摘要：[目的] 待补。[方法] 待补。[结果] 待补。[结论] 待补。

关键词：多时相遥感影像；时空深度学习；空间泛化；农作物识别

【中图分类号】P237　　【文献标志码】A　　【文章编号】1009-2307（20 ）0 -

Spatiotemporal Deep Learning for Remote Sensing Identification of Corn and Soybean with Spatial Generalization

HUANG Youyuan[1], LIN Na[1], FAN Li[2]

(1. School of Smart City, Chongqing Jiaotong University, Chongqing 400074, China;
2. China Meteorological Administration Key Open Laboratory of Transforming Climate Resources to Economy, Chongqing Meteorological Service Center, Chongqing 401147, China)

Abstract: [Purposes] **TBD**. [Methods] **TBD**. [Findings] **TBD**.

Key words: multi-temporal remote sensing imagery; spatiotemporal deep learning; spatial generalization; crop identification

0 引言

1 研究区域与数据

1.1 研究区概况

4 个站点均位于美国中西部玉米带内，该区域以玉米和大豆种植为主，分别记为 A、B、C 和 D，自西向东排列顺序为 A、B、D、C。四站彼此相互独立，站点中心间距平均约 452 km，最大约 793 km；各站均为 76.8 km × 76.8 km 的正方形区域，边界沿等积投影的坐标轴方向延伸，与经纬线方向存在一定偏差。四站中心坐标依次为 A（西经 95.9085°、北纬 42.8746°）、B（西经 91.6892°、北纬 42.2382°）、C（西经 86.7671°、北纬 40.7431°）和 D（西经 89.2372°、北纬 40.1071°）。四站 2023 年地物分类图见图 1，子图采用相同的范围和显示比例，排列仅反映版面顺序，不表示站点间的实际方位。

图 1 中的数据来自美国农业部国家农业统计局（USDA NASS）发布的耕地数据层（Cropland Data Layer，CDL）。基于 2023 年 CDL 数据统计结果，4 个站点均以玉米和大豆为主要作物类型，两者面积之和均超过农作物总面积的 90%。本文将 CDL 原始类别重分类为玉米、大豆和其它地类 3 类，其中除玉米和大豆以外的农作物和非农作物地类均归并为其它地类。四站均以玉米和大豆为主要作物，但地物组成与景观格局存在差异。

玉米和大豆的物候信息来自美国农业部国家农业统计局发布的作物进度报告（Crop Progress Report，CPR）。结合该报告，本文以年积日（DOY）116–266 作为主要观测窗口，该窗口覆盖玉米和大豆的主要生育阶段。

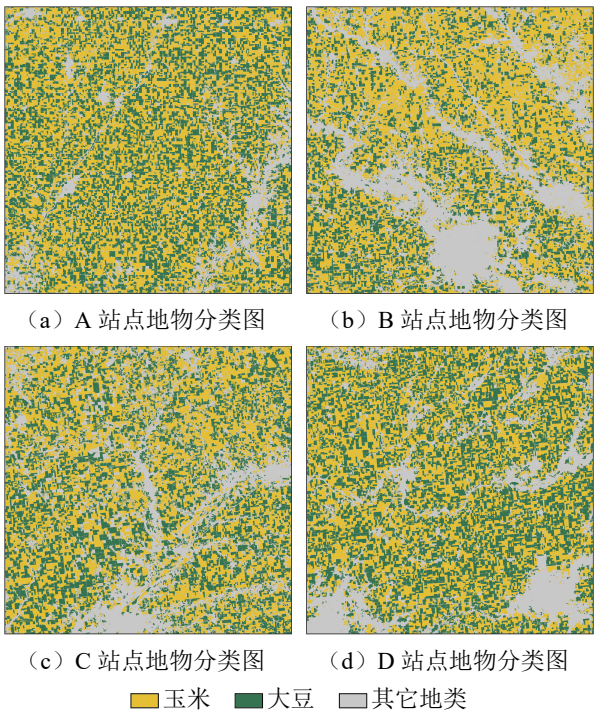


图 1 四个研究站点 2023 年地物分类图

1.2 数据获取与预处理

本文采用的多时相遥感数据源自美国国家航空航天局（NASA）地球数据科学系统提供的协同陆地卫星和哨兵 2 号数据（Harmonized Landsat and Sentinel-2，HLS）第 2 版。该产品通过对 Landsat-8/9 OLI 与 Sentinel-2 MSI 的观测影像进行辐射定标、大气校正、几何精校正以及网格重采样，实现了两类卫星数据的深度融合。本研究选取其空间分辨率为 30 m 的多时相地表反射率数据，包含蓝光、绿光、红光、近红外、短波红外 1 和短波红外 2 共 6 个核心波段作为深度学习模型的输入特征。

标签数据采用 USDA NASS CropScape 门户网站提供的 2023 年 CDL 产品。CDL 数据提供了美国本土逐像素的年度作物类型分类信息，在本研究中用于模型训练的真值标记与精度检验。研究对原始的 CDL 分类体系进行重分类，统一划分为玉米（Corn）、大豆（Soybean）和其它地类（Others）3 个目标类别。重分类后的标签数据在空间投影和分辨率上与对应的多时相 HLS 影像进行严格对齐。

在预处理阶段，首先对影像进行镶嵌、云掩膜和裁剪处理。随后，对时间序列采用时序线性插值方法补齐无效观测，并统一 4 个站点的时间跨度与时间间隔。最终，构建得到空间大小为 2560×2560 像素，时间分辨率为 5 天、包含 31 个时间步、空间分辨率为 30 m、光谱波段数为 6 的数据集。样本构建时，将多时相影像及其对应标签裁剪为 128 × 128 像素图块，相邻图块无重叠；在此基础上，最终每个站点每年获得 400 个样本用于后续模型训练与验证。

1.3 研究区空间特征

景观格局可从景观组成和空间配置两方面描述：前者指各地类的面积比例，后者指斑块的大小、形状、数量、聚集与邻近以及不同地类之间的交界等空间排布特征，可由斑块、类别和景观 3 个层级的景观指数定量描述 [1]。本文为玉米和大豆选取 7 项指标：面积占比描述景观组成；斑块面积（AREA）、形状指数（SHAPE）、斑块数、聚集度指数（AI）、同类最近邻距离（ENN）和边界密度（ED）分别描述斑块的大小、形状、数量、聚集、邻近以及单位面积内的地类边界长度。其中 AREA、SHAPE 和 ENN 为斑块级指标，面积占比、斑块数和 AI 为类别级指标，ED 为按玉米、大豆和其它地类 3 类计算的景观级指标。各指标均基于 2023 年 CDL 重分类标签计算，斑块按 8 邻域规则识别。

四站在景观组成、作物聚集度和邻近程度上相近（表 1）。景观组成方面，玉米和大豆合计占各站总面积的 65.57%～82.16%，其中玉米占 39.97%～45.39%，大豆占 23.49%～36.77%，两种作物在四站均为主要地类；各站玉米面积均多于大豆，其中 B 站玉米面积约为大豆的 1.8 倍，其余三站两种作物的面积比为 1.10～1.26，面积较均衡。聚集度方面，玉米和大豆的 AI 分别为 91.88%～93.92% 和 91.22%～93.46%，即同类像元邻接数达到其最大可能值的九成以上，两种作物在四站均以连片分布为主。邻近方面，四站两种作物的 ENN 中位数均为 67.08 m，即半数作物斑块与最近同类斑块的距离仅约 2 个像元。ENN 最大值仅由最孤立的单个斑块决定，易受个别斑块影响，因此本文以 90% 分位数描述其分布上端；四站 90% 分位数为 152.97～240.00 m，即九成作物斑块与最近同类斑块的距离不超过 5～8 个像元。总体上，四站作物斑块与同类斑块普遍邻近。

四站的差异主要体现在斑块数量、斑块大小与形状以及边界密度上。斑块数量方面，C 站玉米和大豆斑块数分别为 29837 和 27894 个，其余三站为 14407～16756 个，C 站多出的主要是小斑块：C 站两种作物中小于 10 ha 的斑块均约占斑块数的九成，面积却均不足该作物总面积的 6%。斑块大小与形状方面，各站单像元斑块占作物斑块数的 44.31%～54.64%，面积仅占 0.23%～0.71%，因此图 2 按面积统计：对四站两种作物采用相同的 6 档 AREA 和 4 档 SHAPE，计算各组合内斑块面积占本站该作物总面积的比例。A 站两种作物

SHAPE 小于 2 的斑块面积占比为 78.27% 和 80.82%，面积占比最大的组合均为 100≤AREA<200 ha、1.5≤SHAPE<2；C 站相应占比仅为 46.27% 和 53.84%，AREA≥200 ha 且 SHAPE≥3 的大型复杂斑块面积占比则为 16.78% 和 10.09%。B 站玉米面积占比最大的组合为 200≤AREA<500 ha、2≤SHAPE<3，大豆为 10≤AREA<50 ha、1≤SHAPE<1.5；D 站两种作物面积占比前三位的组合相同。边界密度方面，四站 ED 为 51.76～65.53 m/ha，C 站最高，D 站最低，即 C 站单位面积内的地类边界最长，D 站最短。

综合来看，A 站两种作物的面积主要位于中等大小、形状规则的斑块中；相比 A 站，C 站既有大量小斑块，又有较多面积位于大型复杂斑块中，边界密度也最高。B 站玉米与大豆的面积—形状分布差异明显，玉米面积占比最大的组合对应更大的 AREA 和更高的 SHAPE；D 站两种作物的面积—形状分布相近，边界密度最低。

2 研究方法

2.1 时空深度学习模型

2.1.1 U-TAE 模型

2.1.2 3D U-Net 模型

2.1.3 ConvGRU 模型

2.2 实验设计

本研究围绕玉米、大豆与其它地类三类目标，设计站内分类实验与跨站点空间泛化实验，以评估三种时空深度学习模型的分类能力与空间泛化性能。

2.2.1 站内分类实验

站内实验中，每个站点用 2023 年多时相 HLS 影像和 CDL 标签构建 400 个互不重叠的图块样本，采用 5 折交叉验证训练和评估。400 个样本分为 5 个互不重叠的子集（折），每轮取其中 3 个子集训练、1 个子集验证（用于早停）、1 个子集测试。5 轮之后，每个样本恰好被测试一次，得到覆盖全站的交叉验证预测。

站内精度由 5 折测试的混淆矩阵汇总计算：将 5 个混淆矩阵逐元素相加，再由汇总混淆矩阵计算玉米 F1、大豆 F1 和 OA，得到基于全站预测的站内汇总精度，用作与跨站结果比较的基准。另计算每种模型在每个站点的 5 折测试 F1 均值与标准差，用于说明折间差异；该统计量不参与跨站比较。后文如无特别说明，站内精度均指汇总精度。

三种模型均用 PyTorch 实现，训练策略和超参数统一：优化器为 AdamW，损失函数为交叉熵，初始学习率 0.0001，批次大小 4，余弦退火学习率调度（$T_{\max}=50$，$\eta_{\min}=0.00005$），权重衰减 0.00005，梯度裁剪阈值 5.0，并采用早停（容忍 15 轮，最小改善量 0.0001）防止过拟合。训练时对每个图块做 0°、90°、180°、270° 四种旋转增强，每折有效训练样本由 240 扩展到 960。所有模型在同一硬件环境下训练。

2.2.2 跨站点空间泛化实验

在跨站点泛化实验中，依次选取四个站点之一作为源站点，利用其站内实验训练所得的 5 个模型（每折一个），分别对其余三个目标站点的全部 400 个图块逐块推理。每条迁移路径得到 5 次完整预测，每次将 400 个图块的混淆矩阵汇总后计算指标，再对 5 次结果取均值与标准差。迁移过程中不微调、不集成，以比较三种模型结构的分类性能与空间泛化性能。4 个站点轮换作为源站点，共 12 条有向迁移路径，3 种模型合计 36 个模型—路径组合、180 次完整预测。

为衡量跨站应用的精度与目标站当地训练精度之间的差距，本文以同一模型在目标站点的站内汇总 F1 为基准，计算 F1 差值。以玉米为例：

$$\Delta F1_{\text{玉米}} = F1_{\text{目标站站内玉米}} - \overline{F1}_{\text{跨站玉米}} \tag{1}$$

式中，$F1_{\text{目标站站内玉米}}$ 为该模型在目标站点的站内汇总玉米 F1，$\overline{F1}_{\text{跨站玉米}}$ 为源站点模型在目标站点的跨站玉米 F1 五次均值，计算时二者取值均为 0～1。$\Delta F1_{\text{玉米}}$ 为二者直接相减的差值，正值表示跨站精度低于目标站点的站内精度，负值表示跨站精度高于站内精度。大豆的 F1 差值 $\Delta F1_{\text{大豆}}$ 同理计算。F1 及其标准差以百分数表示，F1 差值以百分点表示，均将原尺度数值乘以 100 后保留两位小数；计算和比较使用未舍入值，差值不除以站内基准。

2.3 精度评价指标

模型精度由预测结果与像元级真实标签构成的混淆矩阵计算。对玉米、大豆、其它地类三类，混淆矩阵元素 C_{ij} 表示真实类别为 i、预测为 j 的像元数。类别 i 的精确率 P_i 为

$$P_i = \frac{C_{ii}}{\sum_j C_{ji}} \tag{2}$$

召回率 R_i 为

$$R_i = \frac{C_{ii}}{\sum_j C_{ij}} \tag{3}$$

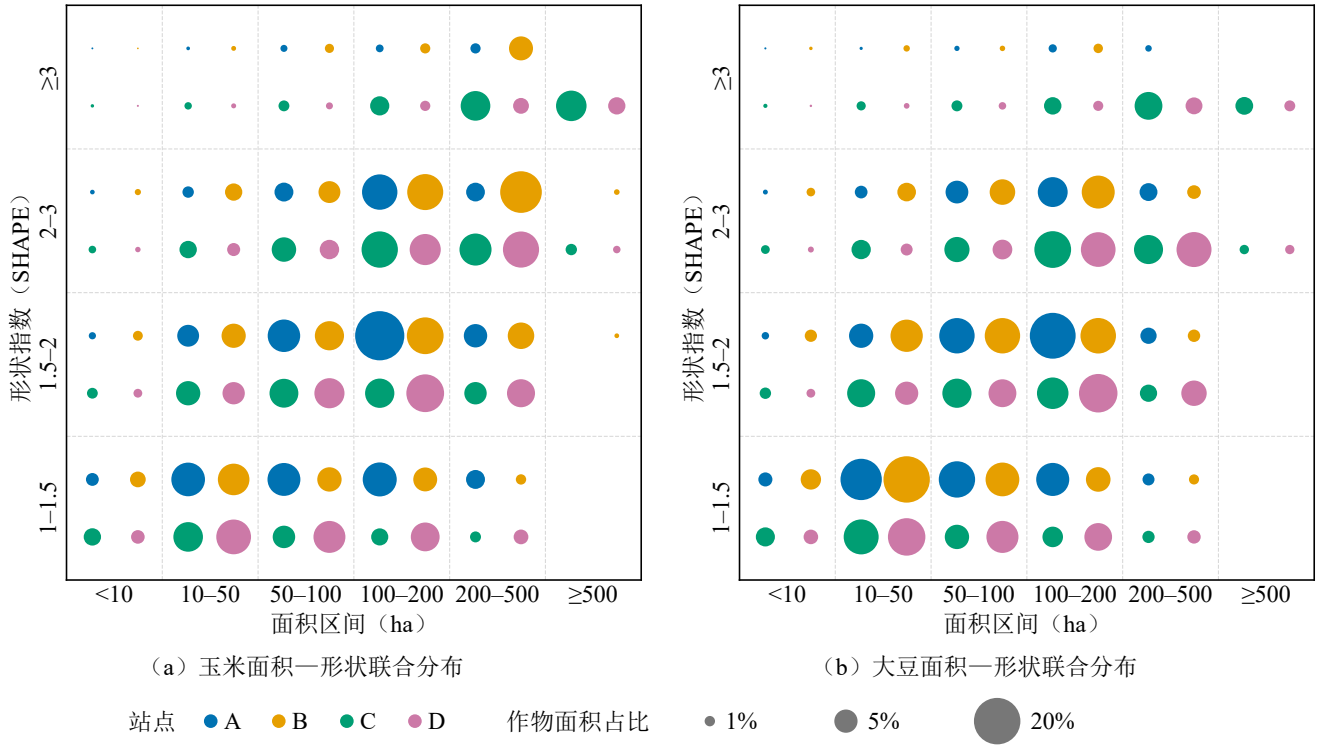
F1 为二者的调和平均：

$$F1_i = \frac{2P_iR_i}{P_i + R_i} \tag{4}$$

表 1 四个研究站点 2023 年玉米和大豆的景观指数

站点	作物	斑块级	类别级			景观级
		ENN（m）	面积占比（%）	斑块数	AI（%）	ED（m/ha）
A	玉米	67.08（60.00～161.55）	45.39	15146	93.92	55.21
	大豆	67.08（60.00～180.00）	36.77	14695	93.46	
B	玉米	67.08（60.00～180.00）	42.08	14460	93.25	54.47
	大豆	67.08（60.00～240.00）	23.49	16039	91.60	
C	玉米	67.08（60.00～152.97）	40.31	29837	91.88	65.53
	大豆	67.08（60.00～180.00）	31.98	27894	91.22	
D	玉米	67.08（60.00～180.00）	39.97	16756	93.58	51.76
	大豆	67.08（60.00～189.74）	36.44	14407	93.43	

注：ENN 为该作物全部斑块 ENN 的中位数，括号内为最小值～90% 分位数；面积占比以本站全部像元为分母；ED 按玉米、大豆和其它地类 3 类计算。



（a）玉米面积—形状联合分布　　（b）大豆面积—形状联合分布

图 2 四个研究站点 2023 年玉米和大豆的面积—形状联合分布

注：区间左闭右开，末档仅设下限。气泡面积与该 AREA—SHAPE 组合内斑块面积占本站该作物总面积的比例成正比，每个站点每种作物合计 100%；格内 A、B、C、D 站气泡分别位于左上、右上、左下和右下。

总体精度（OA）为

$$\mathrm{OA}=\frac{\sum_i C_{ii}}{\sum_{i,j} C_{ij}} \tag{5}$$

本研究关注玉米和大豆的识别与泛化能力，因此分别报告玉米 F1（$F1_{玉米}$）和大豆 F1（$F1_{大豆}$）作为主要指标，OA 作为总体参考。

为分析分类错误的空间分布，依据参考标签中上下或左右相邻的不同地类像元之间的交界线，将像元中心距最近交界线不超过 30 m 的作物像元划为边界像元，其余划为内部像元。研究区外框、图块分割线及无效数据边缘不作为类别交界。同一目标站的各模型及站内、跨站结果采用相同划分，分别统计玉米和大豆边界与内部的面积占比、漏分率和漏分贡献比例。面积占比为该部分面积占全站该作物总面积的比例；漏分率为该部分被判为其它类别的像元数占其参考作物像元数的比例；漏分贡献比例为该部分漏分像元数占全站该作物漏分总数的比例，并结合斑块面积与形状分组比较分类表现及模型差异。

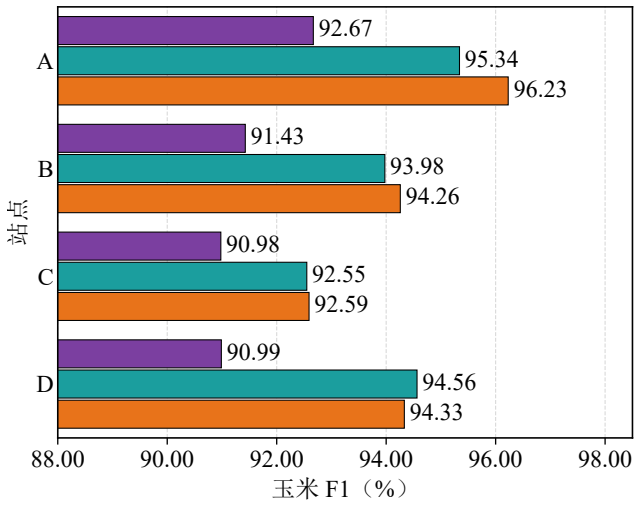
2.4 硬件和软件配置

模型在 Linux 工作站（Ubuntu 22.04）上训练，配置为 Intel Xeon Gold 6430 处理器（2.1 GHz，32 核）、120 GB 内存和 1 块 NVIDIA H100 显卡（40 GB 显存），深度学习框架为 PyTorch。

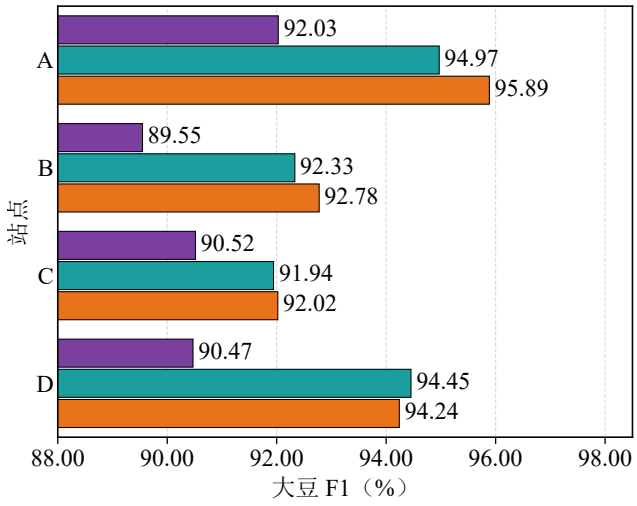
3 实验结果与分析

3.1 模型站内分类性能

如图 3 所示，三种模型在四个站点的站内玉米 F1 为 90.98%～96.23%，大豆 F1 为 89.55%～95.89%。三种模型的分类表现呈现出两点共性：在四个站点上，玉米 F1 均高于大豆 F1，差值均小于 2.00 个百分点；跨站点比较，各模型的玉米和大豆 F1 均在 A 站点取得各自最高值。五折交叉验证中，同一数据集不同划分下的每折独立训练，12 组实验（3 种模型 ×4 个站点）的玉米和大豆 F1 折间标准差均小于 1.00%。



（a）四站点玉米分类精度



（b）四站点大豆分类精度

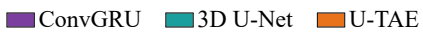


图 3 三种模型在四个站点的站内玉米和大豆分类精度

三种模型之间的差异主要体现在 ConvGRU 与另两种模型之间。U-TAE 和 3D U-Net 在各站点的玉米和大豆 F1 均高于 ConvGRU，而二者之间差值均小于 1.00 个百分点，互有高低：U-TAE 在 A、B 两个站点略优，3D U-Net 在 D 站点略优，C 站点 U-TAE 的玉米和大豆 F1 分别高出 0.04 和 0.08 个百分点。ConvGRU 与前两者的差距因站点而异：两种作物在 C 站点为 1.43～1.61 个百分点，在 D 站点为 3.34～3.98 个百分点。

结合 1.3 节的面积—形状分布，进一步按完整参考斑块分组考察漏分位置，图 4 给出三模型的全站作物对错分布。A 站两种作物面积占比最大的组合均为 100～200 ha、形状指数 1.5～2，分别占全站玉米和大豆面积的 22.42% 和 19.45%。这两个组合的边界占比均低于对应作物的全站水平，三模型的内部漏分率最高为 0.64%，边界漏分率也低于同站对应作物的全站边界水平。主要面积所在组合的边界和内部均有较好的识别表现，与 A 站两种作物 F1 均最高相对应。

B 站大豆较小斑块中的漏分，主要来自有较大面积支持的较规则形状组。面积小于 50 ha、形状指数小于 1.5 的斑块占该站大豆面积的 23.76%，包含三模型全站大豆漏分的 36.89%～37.90%。该组边界占比为 35.42%，ConvGRU 在边界和内部的漏分率分别为 43.21% 和 3.18%，说明漏分量既与边界所占面积有关，也与边界内的识别不足对应。形状指数不小于 3 的小斑块虽有更高的边界占比和组内漏分率，却仅占大豆面积的 0.49%，不是全站漏分的主要来源。D 站两种作物在小于 50 ha、形状指数小于 1.5 组中的面积占比分别为 12.91% 和 14.97%，组内边界占比和内部漏分率也接近，与两作物分类表现接近相对应，但不能仅据面积或形状分布判断识别难度。

模型间漏分差异在 C、D 站对应的组合也不同。D 站玉米 10～50 ha、形状指数小于 1.5 组占玉米面积的 11.19%，3D U-Net 相对 ConvGRU 在该组边界和内部的漏分率分别降低 12.45 和 2.04 个百分点，二者合计占全站玉米漏分净减少量的 20.85%；该组也是 D 站大豆两种比较模型漏分净减少量最大的组合。C 站玉米中，3D U-Net 漏分净减少量最大的组合为 200～500 ha、形状指数不小于 3，占玉米面积的 8.15%，边界和内部漏分率分别降低 1.95 和 1.35 个百分点，占全站玉米漏分净减少量的 10.22%。D 站这一主要组合的改善幅度和贡献均大于 C 站上述组合，但两站其余组合仍共同影响全站差距。ConvGRU 的内部漏分也并非只集中于复杂斑块：A 站两种作物、B 站

大豆和 D 站两种作物的内部漏分计数最多的组合均为 10～50 ha、形状指数小于 1.5，而 C 站玉米为上述大型复杂组合。

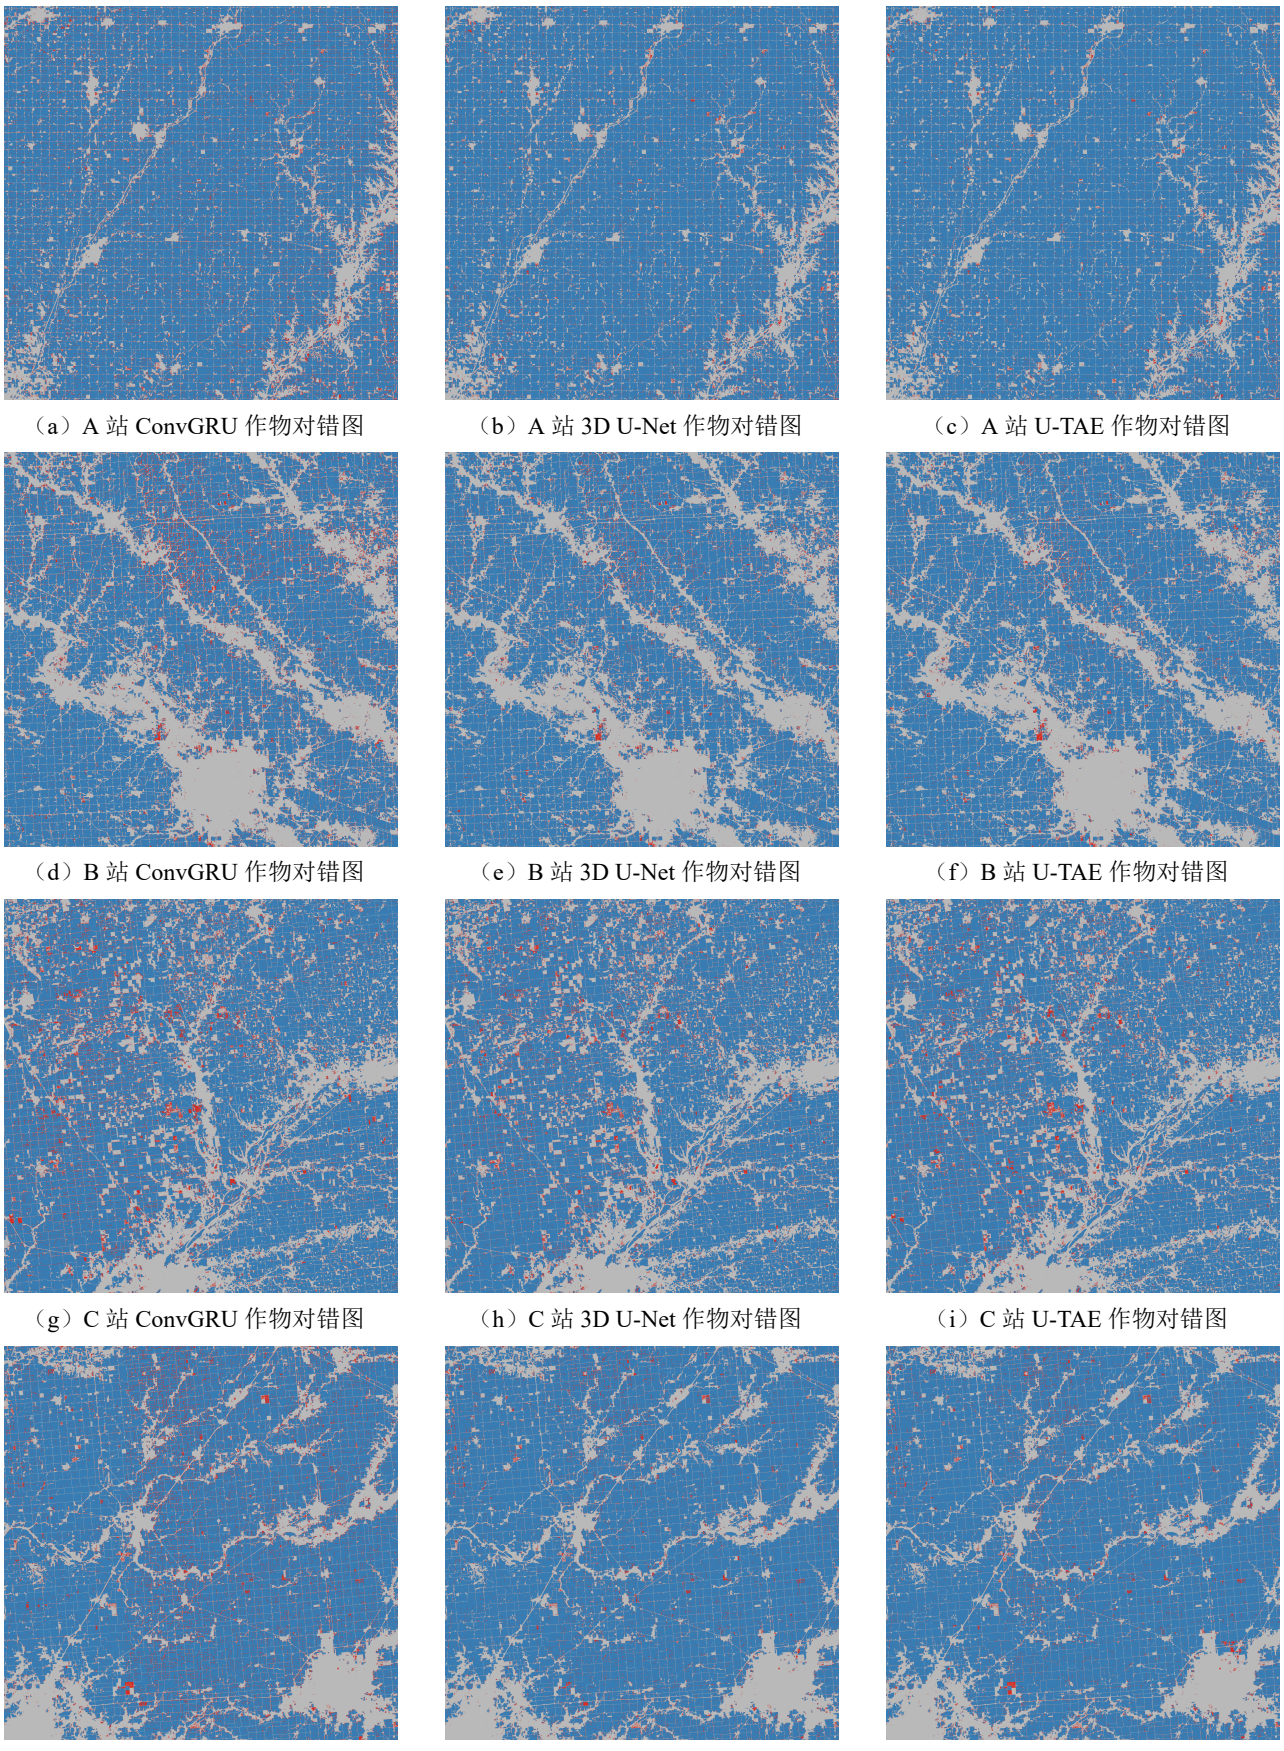
U-TAE 与 3D U-Net 在边界和内部的优势并不总是一致。C 站玉米的全站边界漏分率，U-TAE 为 25.79%，低于 3D U-Net 的 28.03%；内部则为 0.93%，高于 3D U-Net 的 0.81%，D 站大豆也存在同样的位置差异。模型改善还存在反例：C 站面积不小于 500 ha、形状指数不小于 3 的玉米斑块占该站玉米面积的 8.63%，U-TAE 在其内部的漏分率比 ConvGRU 高 0.18 个百分点。图 4 用于观察全站错分的空间聚集，细小边界及组内差异由上述全站统计定位。这些面积—形状与错误位置的对应不表示独立因果作用；作物漏分分析也未包含参考其它地类误分入作物的影响，不能直接分解 F1 差异。

3.2 模型跨站分类性能与泛化退化

如表 2 所示，源站模型不经微调直接用于目标站后，36 个模型—路径组合的玉米和大豆跨站 F1 均低于同一模型在目标站的站内汇总 F1。跨站玉米 F1 为 85.68%～92.92%，大豆 F1 为 83.08%～92.15%，每项为五次完整目标站预测的均值。按目标站对 3 条路径取平均，三种模型的玉米和大豆跨站 F1 均在以 A 站点为目标站时最高，与站内结果中 A 站点精度最高相对应；玉米跨站 F1 则均在以 C 站点为目标站时最低，大豆跨站 F1 的最低目标站则不一致。

按 12 条路径取算术平均，ConvGRU 的跨站 F1 均值最低，但平均 F1 差值最小：其跨站玉米和大豆 F1 分别为 88.73% 和 87.64%，比 3D U-Net 和 U-TAE 低 1.45～2.13 个百分点（后两者两种作物的均值为 89.69%～90.39%）；而玉米和大豆平均 F1 差值分别为 2.79 和 3.00 个百分点，小于 3D U-Net 和 U-TAE（3.74～3.97 个百分点）。跨站 F1 比较的是模型在目标站的实际分类精度，F1 差值衡量的则是跨站 F1 与同一模型在目标站站内汇总 F1 之间的差距。因此，F1 差值较小不代表跨站绝对精度更高，评价模型的跨站表现需要同时考察这两个指标。

如图 5 所示，F1 差值随源—目标组合而变化，且三种模型的变化并不一致。即使目标站相同，F1 差值也会随源站不同而改变：以 D 站点为目标站时，ConvGRU 的大豆 F1 差值在源站为 C 时为 0.90 个百分点，源站为 B 时为 7.39 个百分点；这两种源站下五次预测对应的 F1 差值分别为 0.77～0.99 和 3.29～10.81 个百分点，源站为 B 时的每一次结果均高于源站为 C 时，但五次之间的波动也更大。在 B、D 两个站点之间，两个方向上的 F1 差值大小关系也因模型而异：ConvGRU 的玉米和大豆 F1 差值均为 B→D 方向较大，3D U-Net 则均为 D→B 方向较大；以大豆为例，ConvGRU 在 B→D 和 D→B 路径上分别为 7.39 和 3.36 个百分点，3D U-Net 分别为 4.02 和 6.14 个百分点。上述方向差异基于五次预测的均值，仅反映这一站点对上的表现，不代表普遍的迁移规律。这些差异与站点空间特征的对应关系，将在后文结合地物组成与景观结构分析。



（a）A 站 ConvGRU 作物对错图　（b）A 站 3D U-Net 作物对错图　（c）A 站 U-TAE 作物对错图

（d）B 站 ConvGRU 作物对错图　（e）B 站 3D U-Net 作物对错图　（f）B 站 U-TAE 作物对错图

（g）C 站 ConvGRU 作物对错图　（h）C 站 3D U-Net 作物对错图　（i）C 站 U-TAE 作物对错图

（j）D 站 ConvGRU 作物对错图　（k）D 站 3D U-Net 作物对错图　（l）D 站 U-TAE 作物对错图

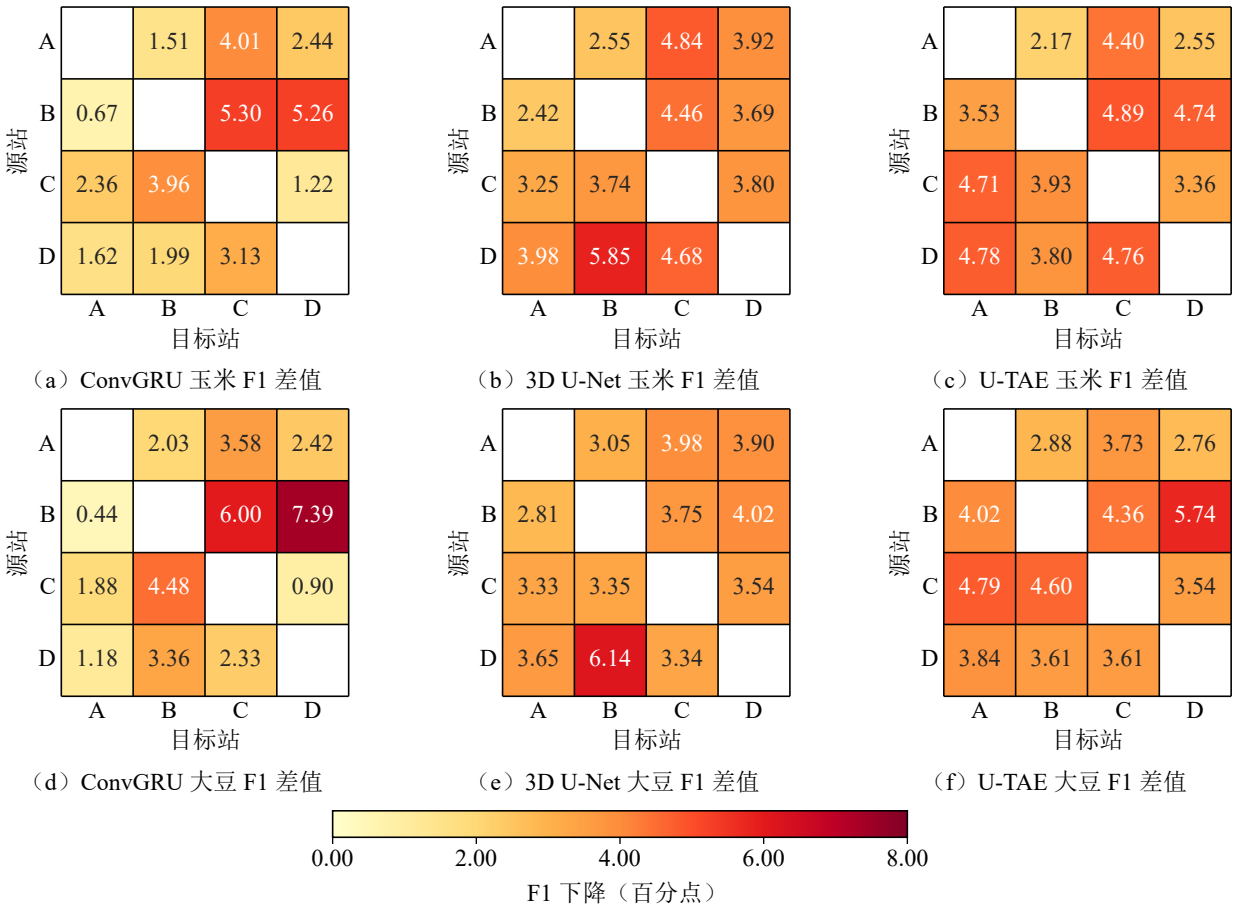
图 4 四站三种模型的全站作物参考像元错分分布

注：红色包括作物间互混及作物判为其它地类，不显示参考其它地类误分入作物的像元。同站三图覆盖一致，各图保留原始像元。

表 2 三种模型在 12 条迁移路径上的跨站玉米和大豆 F1

迁移路径	ConvGRU		3D U-Net		U-TAE	
	玉米 F1（%）	大豆 F1（%）	玉米 F1（%）	大豆 F1（%）	玉米 F1（%）	大豆 F1（%）
A→B	89.91	87.52	91.43	89.28	92.09	89.90
A→C	86.97	86.94	87.71	87.96	88.20	88.29
A→D	88.54	88.05	90.64	90.56	91.78	91.48
B→A	92.00	91.59	92.92	92.15	92.70	91.87
B→C	85.68	84.52	88.09	88.20	87.70	87.66
B→D	85.73	83.08	90.87	90.43	89.59	88.50
C→A	90.31	90.15	92.09	91.64	91.52	91.09
C→B	87.47	85.06	90.23	88.98	90.33	88.18
C→D	89.77	89.57	90.77	90.91	90.98	90.70
D→A	91.05	90.85	91.36	91.32	91.45	92.04
D→B	89.44	86.19	88.13	86.19	90.45	89.17
D→C	87.85	88.19	87.88	88.60	87.83	88.41
平均	88.73	87.64	90.18	89.69	90.39	89.77

注：箭头左侧为源站，右侧为目标站。每格为源站 5 个折模型分别预测目标站全部 400 个图块所得 5 次 F1 的算术平均，以百分数表示，未进行微调和模型集成；“平均”行为 12 条迁移路径 F1 均值的算术平均。



（a）ConvGRU 玉米 F1 差值　（b）3D U-Net 玉米 F1 差值　（c）U-TAE 玉米 F1 差值

（d）ConvGRU 大豆 F1 差值　（e）3D U-Net 大豆 F1 差值　（f）U-TAE 大豆 F1 差值

图 5 不同源—目标区域组合下三种模型的玉米和大豆 F1 差值（单位：百分点；行为源站，列为目标站，对角线不适用；同模型目标站站内 F1 减跨站五次均值，六幅子图共用色标）

3.3 模型跨站泛化差异的空间解释

4 结论

参考文献：

[1] Kevin McGarigal, Samuel A. Cushman, and Eduard Ene. FRAGSTATS v4: Spatial pattern analysis program for categorical maps. URL `https://www.fragstats.org`.