时空协同的农业种植结构遥感精细制图

张冬韵[1,2]，吴田军[3]，骆剑承[1,2]，董文[1,2]，孙营伟[4]，杨颖频[5]，海云瑞[6]，孟博文[2]，刘巍[1,2]

1. 中国科学院空天信息创新研究院 遥感与数字地球重点实验室(中国科学院), 北京 100101;
2. 中国科学院大学, 北京 100049;
3. 长安大学 理学院, 西安 710064;
4. 中国农业科学院农业资源与农业区划研究所, 北京 100081;
5. 广州大学 地理科学与遥感学院, 广州 510006;
6. 宁夏农林科学院农业经济与信息技术研究所, 银川 750000

摘 要：农业是国民经济的重要组成成分，精准地掌握农作物种植结构信息是精细化农业应用的基础。本文挖掘不同源遥感数据的时空特征互补优势，设计了一种时空协同的农业种植结构遥感制图方法，考虑将高空间分辨率遥感影像提取的耕地地块作为基本单元，再结合高时间分辨率遥感影像的光谱时序信息，在深度学习技术支持下实现地块尺度的作物分类识别和种植结构精准制图，进而可分析主要作物的空间分布特征。宁夏引黄灌区的试验案例结果表明：（1）本实验共获取研究区耕地地块149万个，总面积约54万ha，总体分类精度为0.80；（2）相比于利用传统的制图单元和机器学习方法，基于RCF网络从高分影像上获取的耕地地块形态信息更准确，与实际农业耕作管理单元更匹配，基于Bi-LSTM网络进行作物分类能够将时间序列特征的上下文信息考虑在内，且能保证更高的分类识别精度；（3）玉米、水稻、小麦和蔬菜是研究区的主要作物，其中玉米是种植面积最大的优势作物，空间分布最为广泛，菜地主要集中分布在永宁县和青铜峡市，水稻集中分布在灌溉便利的区域，而小麦大规模种植面积较少，其中小麦夏季收割后种植其他作物的情况主要集中于青铜峡灌区，且复种指数呈现由南向北逐渐降低的趋势。

关键词：遥感，作物种植结构，时空协同，深度学习，耕地地块，NDVI时间序列，宁夏引黄灌区

中图分类号：P2

引用格式：张冬韵,吴田军,骆剑承,董文,孙营伟,杨颖频,海云瑞,孟博文,刘巍.2024.时空协同的农业种植结构遥感精细制图.遥感学报,28(8):2014-2029

Zhang D Y, Wu T J, Luo J C, Dong W, Sun Y W, Yang Y P, Hai Y R, Meng B W and Liu W. 2024. Precise crop planting structure mapping method based on spatial-temporal collaboration of remote sensing. National Remote Sensing Bulletin, 28(8):2014-2029[DOI:10.11834/jrs.20241349]

1 引 言

农业是中国国民经济的基础产业。随着大数据、互联网等高新技术的快速发展，农业信息化已成为现代农业发展的趋势，传统的耕作管理方式正逐步向定位化、定量化、数字化的精准农业转变（吴志峰，2020）。精准的农作物种植结构信息是精细化农业研究的基础数据，也是农作物结构优化调整、水土资源管理、粮食安全预警等主要依据（Fritz等，2019；Chauhan等，2019；Punalekar等，2018）。种植结构描述的是一个生产单元活动区内农作物的类型、分布、面积和轮耕信息等综合情况（Weiss等，2020），传统的方式通常采用人工地面调查实现，这种方法费时费力，且容易受到主观因素的影响（吴炳方，2016）。由于遥感技术具有覆盖范围大、获取成本低、重访周期短等特点，可以在较大范围内实现作物分布信息的快速调查与精准制图，在精准农业应用等方面发

收稿日期：2021-05-31；**预印本**：2021-11-08

基金项目：国家自然科学基金(编号:42071316)；国家重点研发计划(编号:2021YFB3900905)

第一作者简介：张冬韵,研究方向为农业遥感智能计算。E-mail：zhangdongyun19@mails.ucas.ac.cn

通信作者简介：骆剑承,研究方向为遥感大数据智能计算与地学分析。E-mail：luojc@aircas.ac.cn

挥了重大作用（赵春江，2014；史舟 等，2015）。

耕地分布信息是种植结构精准制图的基础（Yang等，2017）。自遥感技术初始，各个国家和国际组织便相继发展了农情信息服务平台，对作物的种植面积进行遥感监测（陈沈斌和孙九林，1997；Becker-Reshef等，2010；Wu等，2014）。然而受限于遥感影像的空间分辨率，往往是基于像素的网格进行区域大尺度的耕地分布制图，其提取结果不可避免受到混合像元的影响。随着遥感影像分辨率的不断提高，地物特征所呈现的信息更加详细（Xu等，2020），农业遥感的研究对象也从像元尺度过渡到对象尺度。例如Dronova等（2012）说明了面向对象方法在景观植被分类中的作用，利用面向对象方法提高了分类精度，减少了分类的椒盐现象。然而由于这种基于分割的方法本质上是跟据纹理及光谱特征的相似性自底向上地聚集形成对象（沈占锋 等，2010），并没有充分考虑到遥感影像具有的上下文语义、形态等特征约束，导致制图结果往往无法与实际的农业耕作管理单元相对应，进而使地图使用者难以依据作物专题图对农业活动过程进行准确地感知与决策（刘巍等，2021）。耕地地块作为人类利用土地资源开展农耕活动的基本单元，能对地表作物的形状、位置进行十分精确的表达，相对于对象更能更真实的反映地表作物的类型与生长状况（Wu等，2019）。基于地块的作物分类思想最早由Derenyi（1979）提出，也是中国当下开展作物种植结构调查值得推崇的一种方式。这是因为地块尺度的作物分布信息提取，不仅时效性强、精度高，而且符合中国农村高度分散条件下的精准农业实施。一些研究也表明面向地块的作物分类方法能够提供比基于像元和对象的传统分类法更精确的结果（Sun等，2019；Yang等，2017），然而在目前的进展中以耕地地块为基本单元的作物空间信息提取研究相对较少。

另一方面，不同类型的作物区分往往需要依赖其物候特征的差异，因此基于时序数据对耕地进行作物类型判别是种植结构精准制图的另一重要研究内容（Sun等，2019）。不同作物的耕作节律不同，在发育过程中生长指标存在一定差异，即物候特征不同（Bazzi等，2019），单一时相的遥感影像数据中，作物的光谱信息发生交叉或重叠，物候特征差异不明显，因此单时相的种植结构提取会使作物类型发生混淆与模糊（Khanal等，2017）。随着高时间分辨率卫星数据产品的出现（如MODIS和Landsat TM数据），多时相分析方法在现阶段取得了广泛的应用（Steinhausen等，2018）。该方法主要原理是利用不同类型作物生长的物候特征，与同时期遥感影像的光谱信息变化规律来进行不同农作物类型的识别。例如，谭深等（2019）结合多时相中分辨率的光学、微波遥感数据，采用了按月提取、按直方图大小提取特征的方式，绘制了海南省水稻种植分布图；刘俊伟等（2020）基于时序Sentinel-2影像，利用作物的物候特征与其光谱特征之间的联系，实现了对梨树县作物种植面积和空间分布信息的准确提取。这些研究表明，在光学数据能有效覆盖整个生长期的前提下，基于上述光谱差异的分类方法具有较高的精度与可信度（Belgiu和Csillik，2018）。然而，农业系统是一个复杂的生态系统，作物的生长状态不仅与作物的类型有关，也与农民的播种和收获日期以及当地的气候、土壤条件等常规技术难以掌握与控制的因素有联系。这导致了实际作物光谱时间曲线在分类时引入了一定不确定性（Vuolo等，2018）。此外，经典的机器学习方法，如随机森林和支持向量机，不是针对时间序列数据设计的，而是将每次获取的数据作为作物分类任务的输入特征（Hao等，2015；Zhao等，2021），因此忽略了时间序列的时间依赖性（Zhao等，2019）。近年来，深度学习算法的持续发展，在利用时间序列进行分类时表现出了前所未有的性能。与经典的机器学习方法使用人工提取的特征作为输入不同，深度学习方法允许向机器输入原始的时间序列数据，并自动发现更高层的语义信息或分类所需的特征表达（Zhu等，2017；Ma等，2019），构建较为稳定的分类器，这对于识别作物生长的复杂变化过程实现准确的作物分类非常有帮助。因此，基于深度学习方法对长时间序列光谱指数进行作物分类的研究值得深入，有待开展更广泛的实践和验证，评估其在农作物分类方面的能力和应用潜力。

综合以上两方面，实现农作物种植结构的精准化遥感提取，需要解决两个方面的核心问题，即如何构建精细的耕地地块单元以及如何准确地

识别作物类型。前者解决农作物种植结构信息提取中“精不精”的问题，需要依赖高空间分辨率的遥感影像数据；后者解决农作物种植结构信息提取中“准不准”的问题，需要依赖高时间分辨率的遥感影像数据。然而，由于卫星对地观测的时空分辨率的矛盾，难以在一个数据源上同时获得高空间和高时间分辨率的遥感影像。因此，综合利用不同时空分辨率的遥感数据进行协同分析是农作物种植结构精准制图的必然选择（Duveiller等，2011；Sonobe，2019）。

鉴于此，本文发展一套时空协同的地块尺度作物种植结构遥感制图方法，将从高分辨率遥感影像提取的耕地地块作为基本单元，结合多时相中分辨率影像的光谱信息构建关于归一化植被指数的时间序列，进而在双向长短期记忆网络的深度学习技术支持下实现地块作物类型的准确判别。本文选择宁夏引黄灌区作为试验区，验证了上述方法的可行性与有效性，同时结合作物分类结果进一步分析了试验区小麦、玉米、水稻、菜地等主要作物的空间分布特征，为指导作物种植结构调整和优化提供科学依据。在农业现代化背景下，本文研究将为农作物种植结构的快速、精准调查提供技术方法参考，期望相关技术成果能为精准农业的管理提供可靠的信息底图。

2 研究区与数据

2.1 研究区概况

宁夏回族自治区位于黄河中上游，地处35°14′N—39°23′N，104°17′E—107°39′E（王幼奇等，2014）。宁夏引黄灌区作为中国干旱半干旱地区的粮食主产区，其地理位置如图1所示，由于黄河从这里经过，给这块干旱的地区能发展农业而注入了血液，灌溉农业发达，故被称为“天下黄河富宁夏”。引黄灌区分布在青铜峡市、永宁县、银川市、贺兰县等11个县市区，灌溉了828万亩土地。该区域属大陆性气候，干旱少雨，灌区年均气温8 ℃—9 ℃，作物生长季节≥10 ℃，积温为3200 ℃—3400 ℃，平均无霜期150—195 d，日照充足，温差较大，热量丰富，属于种一季作物有余、两季作物不足的地区。

宁夏引黄灌区农作物播种类型丰富，主要粮食作物有水稻（4—9月）、玉米（4—9月）、小麦（3—7月）等，经济作物有蔬菜、向日葵、西瓜等。主要的轮作制度为两段轮作制，即1年稻1年旱作物，此种轮作方式有利于改土培肥，改善该地区由于连年种植水稻加剧的土壤盐渍化问题。针对引黄灌区小麦复种两熟制存在的“一季有余，两季不足”的矛盾，近年来宁夏持续推进春小麦复种两熟模式示范，重点推广冬春麦后复种青贮玉米、蔬菜、油葵等作物的技术模式，作物与播种制度的多样性丰富。综上所述，在宁夏引黄灌区开展作物种植结构信息的遥感提取具有较强的典型性与代表性。分析清楚该区域的作物空间分布格局，对于实现当地农民增收，推动农业高质量发展具有重要战略意义。

2.2 数据来源

本研究所采用的数据主要包括遥感影像数据和地面采样数据。其中，遥感影像数据主要包括Google Earth影像和Sentinel-2影像。由于地块的边界信息在一段时间内相对稳定，虽然Google Earth数据是由不同时期的影像拼接而成，但其提供了详细的地物空间特征和边缘信息，因此本研究获取了2020年Google Earth高分辨率合成影像用于提取耕地形态信息，空间分辨率为1 m。Sentinel-2A/B卫星搭载了具有13个波段的MSI成像传感器，可覆盖可见光波段至短波红外波段，分辨率最高可达10 m，且具有5—6 d的重访周期，并于2016年起对全球进行免费开放（https：//scihub.copernicus.eu/[2021-05-31]）。选取2020年3月7日至2020年10月21日，33期共225景Sentinel-2A/B遥感影像，时间跨度覆盖宁夏引黄灌区农作物的播种、生长、成熟期（图2）。本研究选取的L2A级数据是已经过辐射定标和大气校正的大气底层反射率数据，影像数据云量均在30%以下。影像预处理包括波段合成、栅格影像重采样、拼接、裁剪处理和投影转换等。

野外调研时发现，该区域的农作物主要包括水稻、小麦、玉米、豆类、油料（油葵）、药材（枸杞、麻黄）、蔬菜（西红柿、西蓝花）、瓜果类（西瓜、葡萄）、青饲料及其他农作物等8大类。根据研究区内作物种植特点和种植面积情况，本文工作主要面向3种主要粮食作物（水稻、小麦、玉米）和3种经济作物（菜地、果园、苜蓿），（其中水稻、玉米和小麦为一年一熟作物，菜地和苜蓿

为一年三至四熟作物。由于近年来，宁夏大力推广麦后复种大豆、饲草、青贮玉米等种植新模式，因此本文将一地两茬种植的经营方式作为种植结构提取类型的一种，在文中对小麦收割后种植其他作物的场景进行讨论，为与单种小麦区分，本文简记为“小麦复种”）。

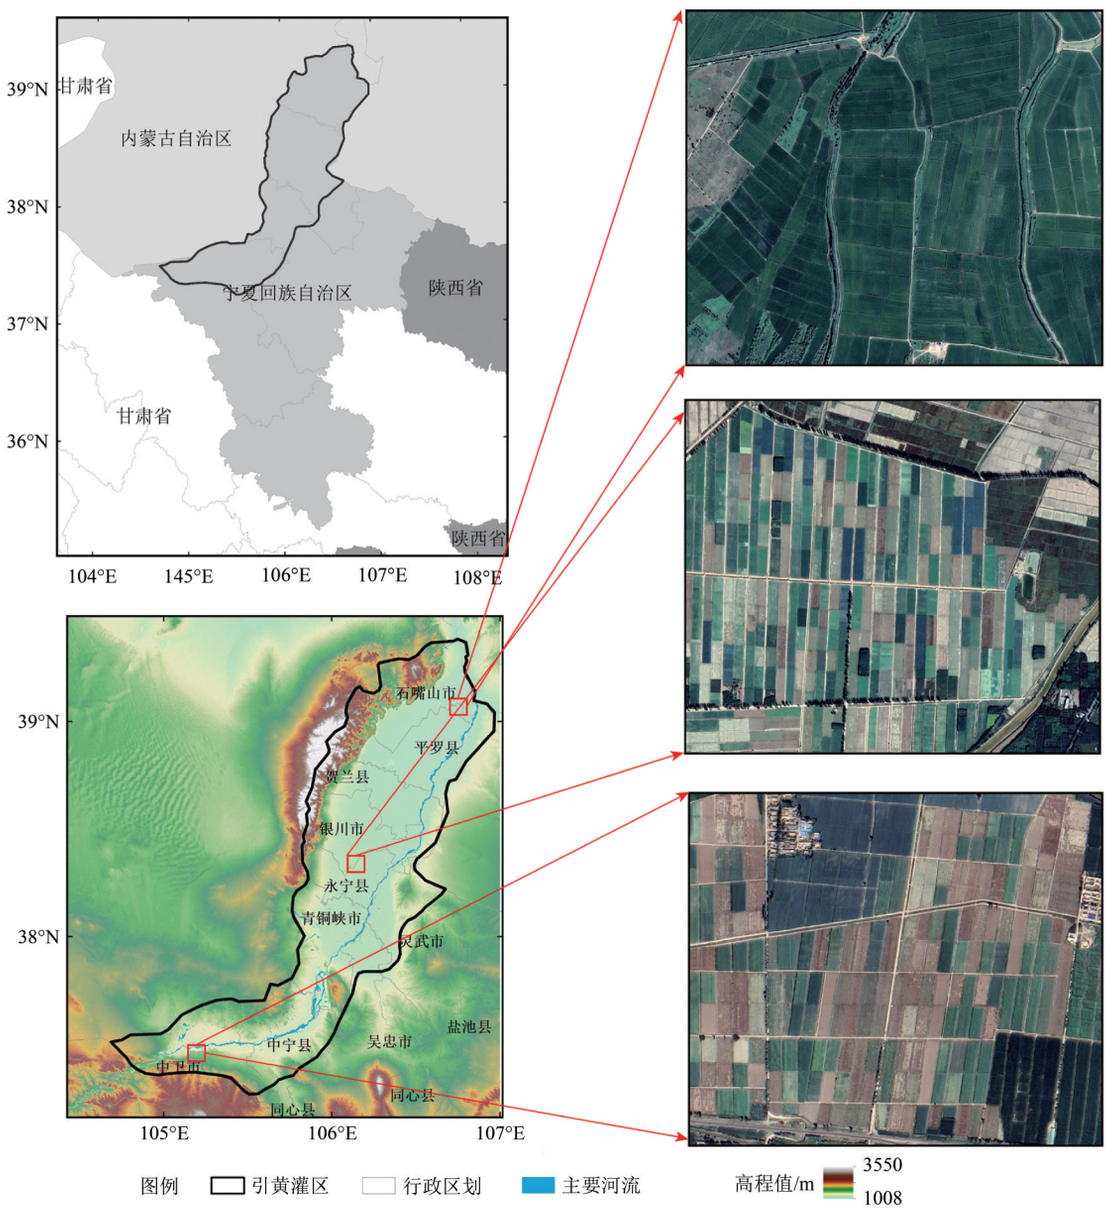


图1 研究区位置、地形以及部分区域的Google Earth影像切片

Fig. 1 Location and topography of study area and local enlarged view of Google Earth image

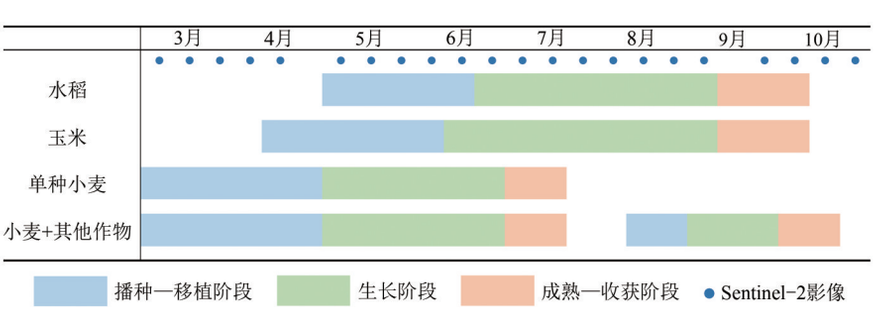


图2 研究区主要作物的生育期和Sentinel-2影像采集日期

Fig. 2 The phenological calendar of the main crops in the study area and Sentinel-2 image acquisition dates

本研究利用手持GPS进行作物定位调查，通过地面采样收集了465个耕地地块采样点的空间坐标和种植作物类型信息。另外，在Google Earth高分影像上随机生成样本点，通过参照地面点的人工目视解译方法，补充了模型训练及验证所需的作物类型样本，最终得到了8大类作物的2470个地块样本，包括水稻584个、单种小麦377个、复种小麦326个、玉米579个、菜地249个、果园76个、苜蓿186个、其他作物92个。样点位置的空间分布如图3所示。此外，本文选用2020年宁夏农作物播种面积统计数据进行对照，数据来源为2020年《宁夏统计年鉴》。

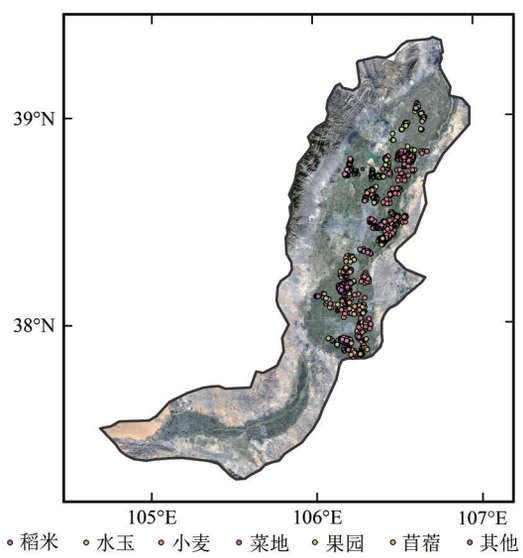


图3 研究区地面采样点

Fig. 3 Ground sampling points in the study area

3 研究方法

本研究协同利用高空间和高时间分辨率的遥感影像数据提出了如图4所示的农作物种植结构信息提取技术路线：首先，通过RCF（Richer Convolutional Features）网络从Google Earth影像上提取耕地地块，结合多期的Sentinel-2数据集构建地块尺度上的作物归一化植被指数NDVI（Normalized Difference Vegetation Index）时序曲线；其次，结合实地调查样本构建基于双向长短期记忆网络Bi-LSTM（Bidirectional Long and Short-term Memory Network）的作物分类模型，进行宁夏引黄灌区作物识别与种植结构精准制图；最后，对提取结果进行精度评价，并定量分析种植结构的空间分布特征。该方法中的关键步骤如下图4所示。

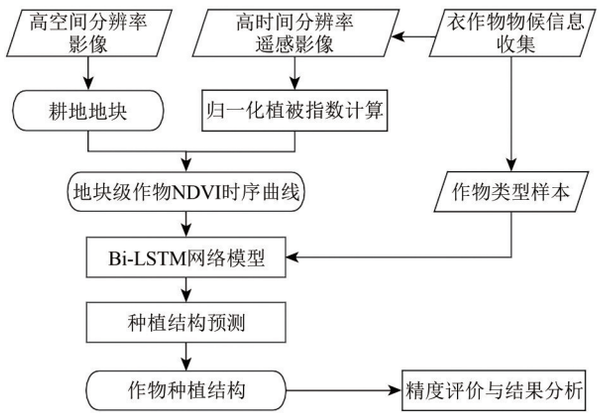


图4 地块级作物种植结构信息提取技术路线

Fig. 4 The technical route of planting structure information extraction at cropland-parcel scale

3.1 基于高空间分辨率影像的耕地地块提取

在作物种植结构精准制图中，构建地块底图是先行研究内容，也就是从高空间分辨率遥感图像中提取农业生产的基本单元——“耕地地块”（Wu等，2020）。引黄灌区所在的地貌类型为黄河冲积平原，地势平坦，耕地几何形态较规则，具有清晰的边缘信息，地块内部作物类型较为单一，在高分遥感影像上表现为形态近似为四边形，分布整齐，内部较均匀的面状地物。基于上述特点，本研究采用对于耕地边界识别有比较好的效果的RCF网络（Liu等，2019）进行耕地地块的边缘检测（Liu等，2020）。

RCF网络的训练需要大量标注数据，本研究在Google Earth高分影像上随机选取50个1000×1000像素的子区域作为训练样本。通过目视解译对其中的农田地块边界进行勾绘，以此作为训练样本输入，学习获得地块边界预测模型。最终获取了研究区的农田地块，共约149万个，典型地块的细节如图5所示。此外，本研究为比较空间约束对提取结果的影响，选择传统的制图单元作为对比实验，包括以像素为最小制图单元和以多尺度分割对象为最小制图单元。

3.2 地块尺度的作物时序特征提取

地块尺度上时间序列数据集的建立是进行地块级作物种植类型识别的前提。本研究采用植被指数作为光谱特征指标，以3.1节中提取的农田地块作为最小的种植单元，利用多时相的Sentinel-2中分辨率数据集构建地块尺度上的作物光谱特征时序曲线，实现对农田作物生长期内生长状态变化的特征描述。

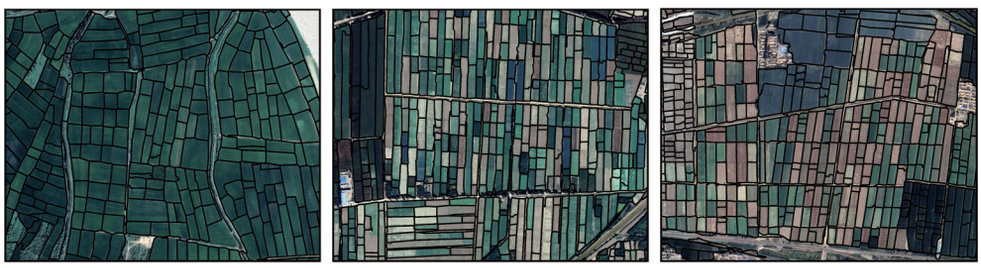


图5 耕地地块提取效果

Fig. 5 Extraction effects of cropland-parcels

NDVI是反应植被长势和作物生长物候阶段的重要参数，且能在一定程度上消除太阳高度角、卫星观测角以及云的影响，是进行植被覆盖分类的良好指标（Ashourloo等，2019）。因此，本研究对地块边界内的NDVI像元值求取平均值作为该地块的NDVI特征值，再经过异常值剔除、缺失值插补后，可在每个地块上得到一条相对平滑的时序变化曲线。

3.3 基于Bi-LSTM的时间序列分类

循环神经网络RNN（Recurrent Neural Network）是序列特征分类的常用模型，但是在设计的网络结构较为复杂时，容易出现梯度爆炸或梯度消失的现象（Pelletier等，2019）。长短期记忆网络LSTM是RNN中性能最好的网络之一（Hochreiter和Schmidhuber，1997），它添加了隐藏层信息的交互机制，解决了长序列数据计算过程中梯度消失或爆炸的问题，在时间序列分析中得到了广泛的应用（Zhou等，2019）。

LSTM单元由两种细胞状态——记忆状态（C^t）和隐藏状态（h^t）和3种不同的门——输入门（i^t）、遗忘门（f^t）、输出门（o^t）组成。首先，通过Sigmoid函数决定在多大程度上现有的储存内容被遗忘，如式（1）所示：

$$f^t = \delta\left(W_f \times \left(x^t, h^{t-1}\right) + b_f\right) \tag{1}$$

其次，通过下一层的输入门i^t决定多少输入信息可以通过，并对该位置中的值进行更新然后生成一个新的单元值C^t，如式（2）所示：

$$i^t = \delta\left(W_i \times \left(x^t, h^{t-1}\right) + b_i\right) \tag{2}$$

然后，利用上一状态的C^{t-1}与当前的遗忘门信息相乘，加入当前状态并更新上一状态值，如式（3）所示：

$$C^t = \tan h\left(W_c \times \left(x^t, h^{t-1}\right) + b_c\right) + f^t \times C^{t-1} \tag{3}$$

最后，通过输入门o^t以及新的Sigmoid函数获得初始值相乘输入当前状态的内容，如式（4）、（5）所示：

$$o^t = \delta\left(W_o \times \left(x^t, h^{t-1}\right) + b_o\right) \tag{4}$$

$$h^t = o^t \times \tan h(C^t) \tag{5}$$

单向模型通过一定的顺序读取NDVI时间序列特征值，即从播种阶段到成熟阶段，由此来得到NDVI特征值在时序曲线中的天数信息，模型实际上只使用到了“前序”的信息，没有考虑到“后序”的信息。然而，在实际场景中，作物的生长状态可能与农民的播种与收获日期、当地的气候与土壤条件等复杂情况有关，因此预测可能需要使用到整个输入序列的信息。双向长短期记忆网络Bi-LSTM在传统单向的LSTM基础上，结合了输入序列在前向和后向两个方向上的信息。已有的研究表明，这种双向的信息提取有助于时序分类（Wang等，2019）。因此，本研究构建了一个Bi-LSTM网络结构进行作物分类。在原有LSTM网络的基础上，将输出层（h^1，h^2，…，h^t）移除并添加到平均池化层，得到一个没有时间信息的向量h_f，称为前向LSTM。LSTM的反向版本，称为后向LSTM，要求数据按照时间序列逆序输入，这一层的输出用h_b表示。Bi-LSTM即是前向LSTM和后向LSTM的组合。由于LSTM本身不执行类别预测的任务，因此本文在Bi-LSTM网络的顶部添加了一个SoftMAX层来执行多类预测，SoftMAX神经元中最大值对应的类别为预测的最终结果。Bi-LSTM神经网络模型训练与预测过程如图6所示。

在本研究中，将基于作物时间序列特征分类的问题转换成一个序列信息的分类问题，在地块级作物NDVI时间序列的基础上，将地面采样获取的训练样本输入模型，通过多次试验确定了Bi-LSTM模型的最优参数值，最终构建了一个包含3个隐藏层、36个隐藏神经元的双向LSTM网络进行时间序列分类。此外，本研究为比较时间约束对提取结

果的影像，选择传统的作物类型提取方法进行对比试验，即基于决策树的监督分类方法，设定NDVI分类阈值，构建决策树分类规则。同时本文为比较Bi-LSTM和传统的LSTM在本实验中的适用性，也设计了一组对比试验。

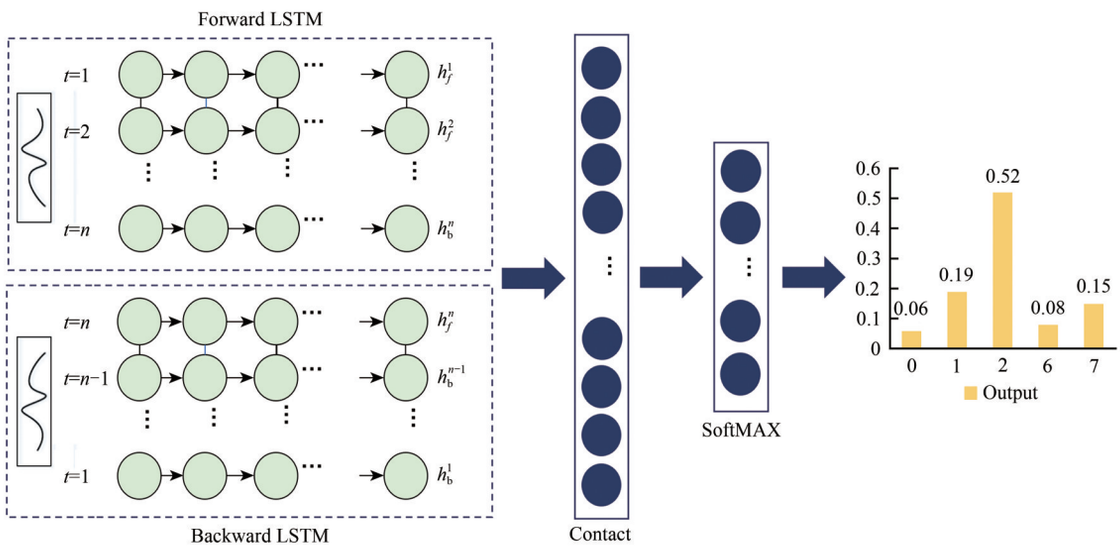


图6 Bi-LSTM神经网络模型训练与预测过程

Fig. 6 Training and prediction process of Bi-LSTM recurrent Neural Network

3.4 精度评价

本研究采用精确率P（Precision）、召回率R（Recall）、总体精度OA（Overall Accuracy）和F_1得分4个度量来评估分类模型的预测性能。另外，由于本研究样本数据集较小，采用10重交叉验证方法，将2470个样本数据集随机划分为10个相等的子集，并以其中1个子集作为验证数据，其他子集的样本作为训练数据，所有分类准确度度量均在十次验证中取平均值。

4 结果与分析

4.1 种植结构提取结果

2020年宁夏引黄灌区夏粮种植结构提取结果和作物种植面积如表1和图7所示，总耕地面积约54万ha。表1中可以看出，种植面积最大的作物是玉米，约21.7万ha，占全区耕地面积的40%以上。其次，宁夏作为农业部规划的蔬菜生产优势区域，菜地（常年种植绿色蔬菜为主的耕地）分布面积约8.7万ha，宁夏菜心、番茄、西蓝花等已成为区域特色优势产品。水稻和小麦种植面积相差不大，分别为6.5万ha和6.3万ha，均占全区耕地面积12%左右。灌区其他作物如果树、苜蓿等种植面积较小，占全区耕地面积的3%。

表1 2020年宁夏引黄灌区作物种植面积

Table 1 Cropland area of Yellow River irrigation area of Ningxia (YRIA-NX) in 2020

作物	面积/hm^2	面积占比/%
水稻	65506.14	12.12
玉米	216513.17	40.06
小麦	63373.70	11.72
菜地	87423.89	16.17
果园	2707.23	0.50
苜蓿	18629.56	3.45
其他	86356.65	15.98
总和	540510.33	

图8为本文提取结果与统计年鉴中各县市农作物播种面积统计数据的线性回归分析示意图。本文提取结果与统计年鉴的种植面积数据相比整体较高，RMSE达6462.5，其中水稻、小麦和菜地的播种面积比通过年鉴所得的各县市播种面积高大约3×10^3—4×10^3 ha，玉米相对高1.1×10^4 ha。统计结果由于技术手段限制（采用逐层上报的方式）存在误报和漏报的情况，因此与通过遥感数据直接获取的农作物面积存在一定差异。

图9和表2是灌区小麦复种情况。小麦复种主要集中在贺兰县、银川市、永宁县和青铜峡市，说明宁夏正从一年一熟的种植模式向一年两熟的

种植模式转变。从图8的复种指数分布趋势上看，由南向北小麦的复种指数逐渐降低，青铜峡市的小麦复种指数达1.55，麦后复种其他作物面积约0.2万ha，平罗县的小麦种植面积最大，但是复种指数较低。这是由于小麦收获后需尽快抓抢农时，而北部灌区的气温较低，小麦的种植时间较南部晚，因此收获时间较晚，且霜冻时间较早，光热条件难以满足麦后复种作物的生长需要，因此灌区北部的小麦复种规模较小。

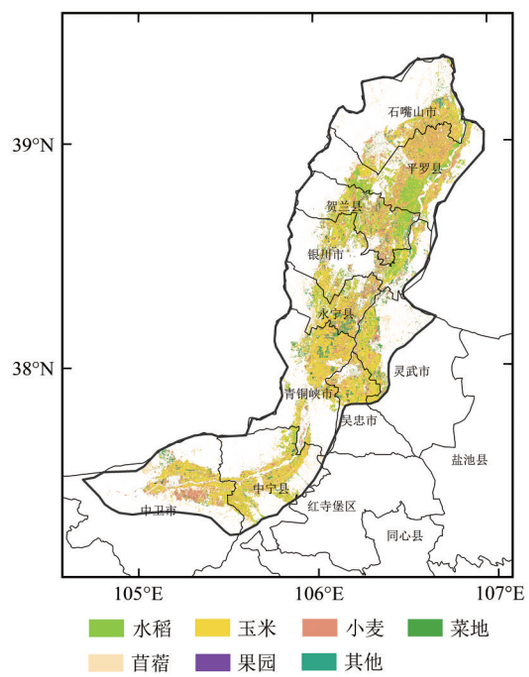


图7 2020年宁夏引黄灌区种植结构

Fig. 7 Planting structure of Yellow River irrigation area of Ningxia (YRIA-NX) in 2020

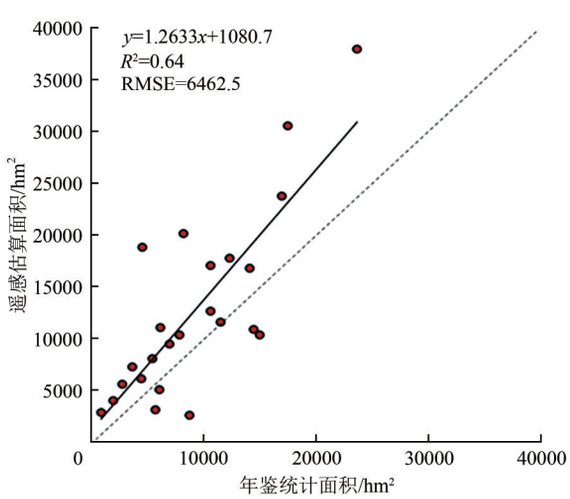


图8 提取结果与统计数据的线性回归分析示意图

Fig. 8 Linear regression analysis schematic diagram of extraction results and statistical data

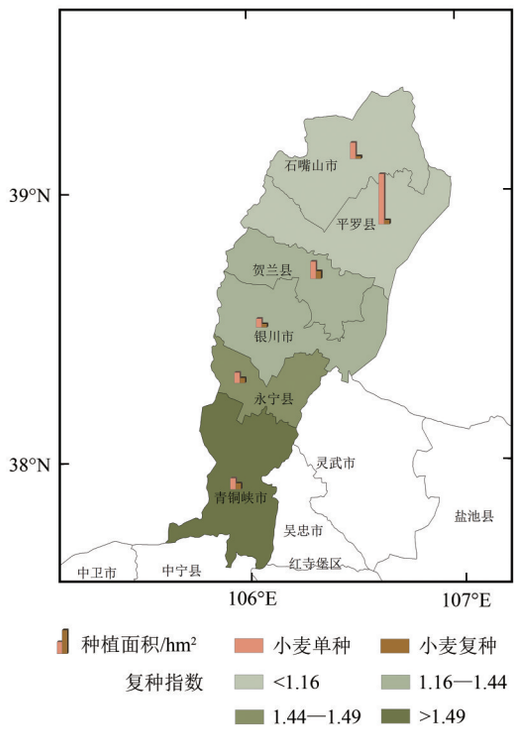


图9 宁夏引黄灌区小麦复种情况分布图

Fig. 9 Distribution map of multiple cropping of wheat in Yellow River irrigation area of Ningxia (YRIA-NX)

表2 宁夏引黄灌区小麦复种情况

Table 2 Multiple cropping of wheat in Yellow River irrigation area of Ningxia (YRIA-NX)

	小麦单种/hm²	小麦复种/hm²	复种指数
石嘴山市	5277.47	863.31	1.16
平罗县	16392.34	1380.48	1.08
贺兰县	5601.71	2485.50	1.44
银川市	2881.39	1142.49	1.40
永宁县	3441.07	1684.99	1.49
青铜峡市	3643.83	2001.52	1.55

4.2 作物分类精度评价

本文针对制图对象和分类方法的使用对种植结构分类提取结果展开分析。图10是采取基于地块的Bi-LSTM神经网络方法分类结果的混淆矩阵。此方法取得了较好的分类精度，总体分类精度为0.80，F_1得分平均值为0.79。对比不同种类的作物，水稻、玉米和菜地的分类效果最好，这是由于这3种类型的NDVI时序特征较明显，但是水稻与玉米这两种作物的波峰位置存在一定的重叠现象，因此该两者之间存在一定的混分现象。最容易被错分、漏分的是单种小麦与复种小麦，这是

由于小麦收割后常会受到杂草的影响，导致NDVI值上升，因此单种小麦容易与小麦复种、苜蓿等多季作物混淆。此外，果园和苜蓿在研究区的分布不占优，但也取得了较高的分类精度。

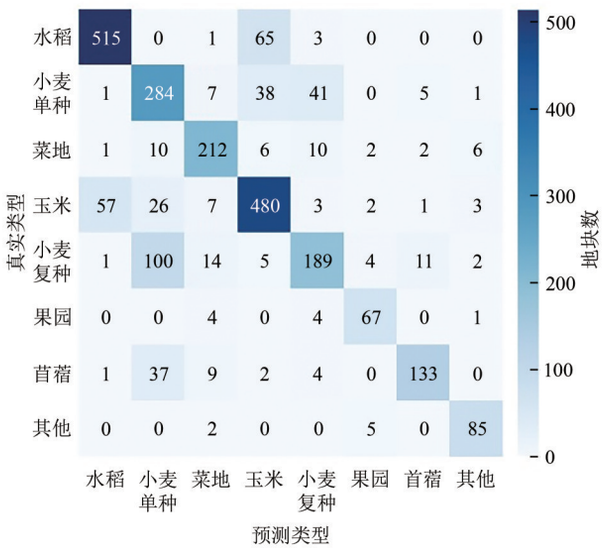
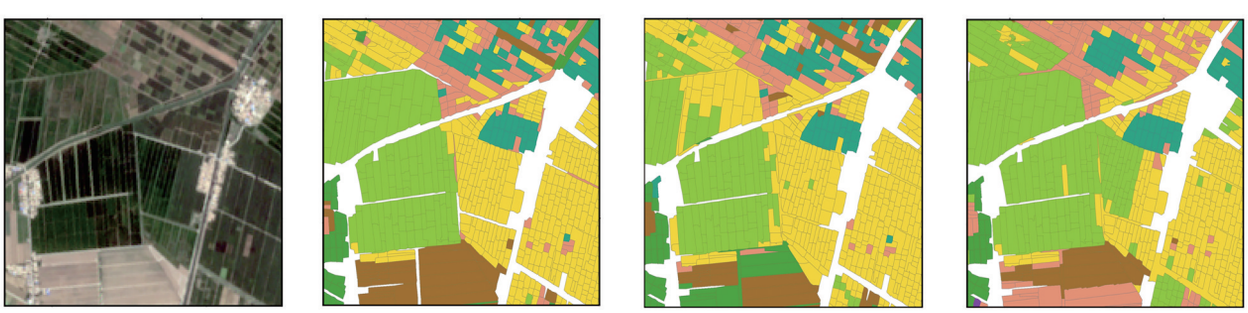


图10 基于地块的Bi-LSTM神经网络方法分类结果的混淆矩阵

Fig. 10 Confusion matrix of classification results based on cropland-parcel and Bi-LSTM neural network method

图11是3种制图对象的提取结果局部放大图。从定性视觉评价来看，不同的制图单元对作物提取的结果有较大影响。基于卷积神经网络方法从高分影像上获取的耕地地块更加完整，边界信息更加准确。以像元为最小制图单元会导致较严重的“椒盐噪声”现象，其提取结果易收到“同谱异物”“同物异谱”的影响。面向对象的方法可以将部分光谱和纹理特征引入耕地的边缘提取过程，在一定程度上减少了“椒盐噪声”现象，但分割对象锯齿较为严重，且作物分类存在不少错分漏分，究其原因是影像分割难以将影像的形态特征考虑在内，从而导致分割边缘不精确，类型判别不准确，分类结果难以应用于农业领域。表3是3种制图对象的种植结构提取结果精度分析比较，以地块为最小制图单元相比于对象和像素具有较大的分类精度优势，分别高0.09和0.20。特别是在小麦和苜蓿的提取中，由于这两种地物光谱特征、纹理特征较近似，在对象分割的过程中容易混淆，导致对象内部存在不同种植类型的地块，而地块内部类型较纯净，因此以地块为最小分类单元更利于提高作物信息提取精度。



（a）Sentinel-2影像
（a）Sentinel-2 image

（b）Bi-LSTM循环神经网络方法
（b）Recurrent neural network based on Bi-LSTM

（c）LSTM循环神经网络方法
（c）Recurrent neural network based on LSTM

（d）基于决策树的监督分类
（d）Supervisory classification based on decision tree

图11 3种制图对象的分类结果

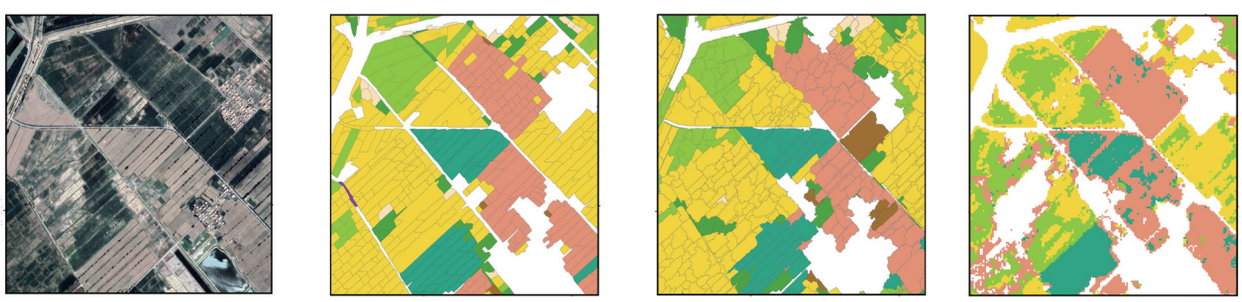
Fig. 11 Classification results of three types of cartographic objects

表3 3种制图对象的精度对比

Table 3 Accuracy comparison of three mapping objects

	基于地块的方法				基于对象的方法				基于像素的方法			
	P	R	F_1	OA	P	R	F_1	OA	P	R	F_1	OA
水稻	0.89	0.91	0.89		0.85	0.80	0.82		0.87	0.79	0.83	
小麦单种	0.62	0.75	0.68		0.60	0.69	0.64		0.52	0.60	0.56	
菜地	0.83	0.85	0.84		0.73	0.83	0.77		0.52	0.81	0.63	
玉米	0.81	0.83	0.82	0.80	0.74	0.88	0.8	0.71	0.74	0.82	0.78	0.65
小麦复种	0.75	0.58	0.65		0.52	0.64	0.57		0.53	0.67	0.59	
果园	0.84	0.88	0.86		0.64	0.82	0.71		0.21	0.44	0.28	
苜蓿	0.88	0.72	0.79		0.52	0.46	0.48		0.40	0.23	0.29	

图12是3种分类方法提取结果的局部放大图。3种分类方法均以地块为最小制图单元，得到了较准确的耕地边缘，能够更直观的看出不同分类方法对分类结果的影响。表4是3种分类方法的种植结构分类提取结果精度分析比较。两种循环神经网络的总体分类结果都较好，Bi-LSTM方法和LSTM方法总体分类精度分别为0.80和0.78，F_1得分的平均值分别为0.79和0.77，而基于决策树的总体分类精度为0.76，F_1得分平均值为0.73。具体来看，3种分类方法都能较好的区分水稻、玉米和菜地，精度均在0.8以上。而容易混淆的单种的小麦和复种的小麦，本文选取的Bi-LSTM模型中表现了较好的优势。果园和苜蓿也在本文采取的方法中具有更高的精度分别为0.86和0.79。以上结果说明以地块为最小制图单元，Bi-LSTM模型相比与传统的监督分类方法具有较好的分类效果：决策树方法加入了专家知识参与分类决策，分类规则明确，但其分类时相和分类阈值的判定具有较大的主观性，易导致部分特征值高于或低于平均值的作物被错分漏分；Bi-LSTM模型基于循环神经网络方法通过计算序列数据中各节点数据之间的隐含关系来表征不同作物之间的差异，从而解决了传统监督分类方法需要人工选择关键时相和分类阈值的问题，能够获得相对较高的精度。



（a）Sentinel-2影像　（b）基于地块的方法　（c）基于对象的方法　（d）基于像素的方法

（a）Sentinel-2 image　（b）Cropland-parcels based method　（c）Object-based method　（d）Pixel-based approach

图12　3种方法的分类结果

Fig. 12　The classification results of the three methods

表4　3种方法的精度对比

Table 4　Accuracy comparison of the three methods

	Bi-LSTM网络方法				LSTM网络方法				基于决策树的监督分类方法			
	P	R	F_1	OA	P	R	F_1	OA	P	R	F_1	OA
水稻	0.89	0.91	0.89		0.84	0.85	0.84		0.83	0.85	0.83	
小麦单种	0.62	0.75	0.68		0.65	0.67	0.66		0.63	0.67	0.64	
菜地	0.83	0.85	0.84		0.84	0.85	0.84		0.81	0.87	0.84	
玉米	0.81	0.83	0.82	0.80	0.80	0.90	0.84	0.78	0.79	0.88	0.83	0.76
小麦复种	0.75	0.58	0.65		0.63	0.60	0.62		0.61	0.51	0.56	
果园	0.84	0.88	0.86		0.64	0.95	0.77		0.63	0.96	0.76	
苜蓿	0.88	0.72	0.79		0.79	0.82	0.80		0.73	0.69	0.70	

4.3　作物生长时间序列曲线分析

图13是研究区6种作物的NDVI时序曲线，包括4种主要作物水稻、玉米、小麦、菜地，以及与菜地生长曲线近似的苜蓿，并对小麦单种和小麦复种进行了对比。从图12可以看出，研究区水稻NDVI曲线最大的特点在于5月份灌水期时NDVI曲线出现一个低值，小于玉米和小麦，这是由于水田对红外光的反射能力较弱。6月份进入分蘖拔节期，NDVI值增长迅速，8月上旬NDVI值增到最大，9月份成熟期后，NDVI值逐渐降低。玉米与水稻的NDVI曲线变化较为相似，但NDVI值增长时期较早。小麦4月中旬开始出苗，之后NDVI值持续增加，在抽穗期达到最大，在此期间其NDVI值远高于玉米和水稻，且相比于其他作物，小麦

的NDVI值的峰值较低。单种小麦在成熟期后，曲线出现上升的原因是小麦收割后受田间杂草的影响，其NDVI值会上升。麦后复种大白菜、小玉米等夏季作物往往在8月上旬开始播种，其生长期较短往往不超过50 d，以保证在霜冻之前完成收获，在此期间NDVI值迅速上升达到峰值，在10月下旬达到成熟期又迅速下降。菜地和苜蓿NDVI的曲线特点是在一年内出现多个峰值，即年内多次重复出现生长—收割循环，NDVI值也呈现出由低逐渐到高、由高迅速降低的变化过程。苜蓿和菜地的区别在于苜蓿返青时间早，在4月上旬就开始了第一季生长，在此期间NDVI值高于菜地，而且苜蓿每隔30—40 d刈割一次，蔬菜的生长周期通常大于30 d，且每次收获后需要重新进行播种，NDVI低值时间持续较长，是与苜蓿区分的特征。

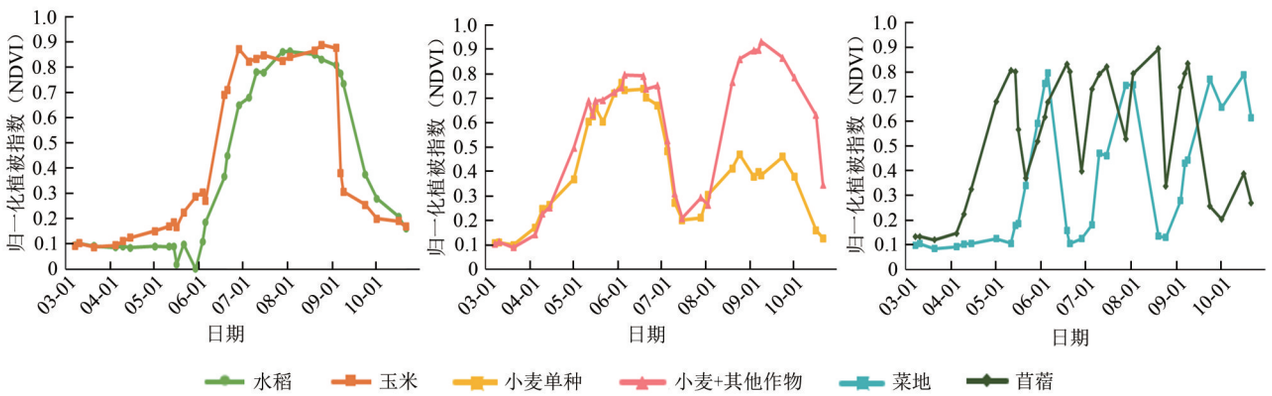


图13 研究区主要作物的NDVI时间序列

Fig. 13 NDVI time series of main crops in the study area

4.4 种植结构空间分布特征分析

各类农作物在空间分布上具有较强的地域性和规律性。首先，水稻主要集中分布在黄河河道两岸，以及河流水渠等灌溉便利的区域，如图14所示，水稻种植比例超过20%的县市有平罗县、贺兰县、银川市，其中平罗县水稻种植面积达2.3万ha，约占灌区水稻种植面积的1/3。银北灌区作为水稻种植优势区域，除了该区灌溉条件好，地形平坦以外，还有一个原因是银北灌区的田块地势低洼，盐碱化严重，只能适宜水稻生长，无法实现其他作物的稻旱连作。其次，玉米作为灌区主要粮食作物，利润相对较高，气候和地域适应性较广，因此玉米种植面积分布最为广泛，各县市种植比例最高的作物均为玉米，其中石嘴山市和青铜峡市玉米种植比例达到50%以上。再次，小麦在引黄灌区的种植面积比例较小，各县市均不超过20%，其中银川北部的平罗县和贺兰县生产规模较大，分别为1.8万ha和0.8万ha。最后，蔬果类作物是宁夏主要种植的经济作物，除平罗县以外，各县市菜地面积比例均达到20%以上，均在1万ha左右。

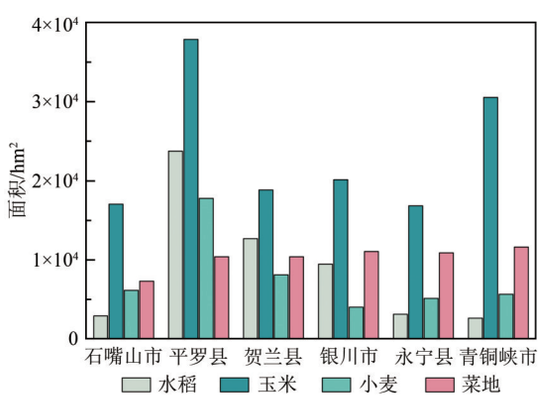


图14 研究区6个市(县)4种主要作物种植情况

Fig.14 Four kinds of main crops planting conditions in six cities (counties) of the study area

本文除了对研究区作物种植面积的数量特征进行总结以外，还采用空间数据统计方法分析了主要作物的地理空间和结构的分布特征。图15绘制了研究区4种主要作物（水稻、玉米、小麦、菜地）的标准差椭圆和中心分布情况。标准差椭圆可以反应要素空间分布的总体轮廓和主导分布方向（宋戈和张文琦，2020）。“重心”在地理学中表示区域地理对象在空间上的平衡点，能够清晰客观反应不同要素的集聚和分散特征和优势区域（王海

军 等，2018）。4种主要作物的耕地利用标准差椭圆均呈东北—西南方向，这与研究区的灌溉水源分布方向基本一致，表明4种作物在灌溉水源附近分布更为密集。其中，小麦的标准差椭圆长轴最长，水稻的长轴最短，玉米和菜地的长轴较近似，说明相比于玉米和菜地，小麦的耕地分布更加分散，水稻的分布最集中。从重心的角度来看，水稻的重心最靠北，位于银川市境内，小麦的重心位于银川市和永宁县交界处，玉米和菜地的重心最靠南，位于永宁县境内，这说明4种作物的空间分布具有较强的地域性，水稻在银北灌区的分布更加密集，而玉米和菜地在青铜峡灌区的分布更加密集。

以此为基础，本文进一步对研究区4种主要作物的空间聚类模式进行分析。如图16所示，本研究基于Getis-Ord Gi*统计绘制具有显著性的热点和冷点图观察局部空间的集聚特征，比较不同作物在空间上发生聚类的位置（Ye等，2018）。总体来看，作物的主要分布都集中在灌溉便利的区域，其中水稻在平罗县的黄河河道两岸以及西北部和南部的河湖水渠交汇处集聚效应明显；玉米在最北端的石嘴山市和黄河上游的中卫市、中宁县、青铜峡市的分布较集中，其分布区域也是最广泛的；小麦在石嘴山市的空间集聚性最高；蔬菜种植基地在永宁县和青铜峡市的分布最多，因此菜地的集聚效应主要发生在这两个县市。

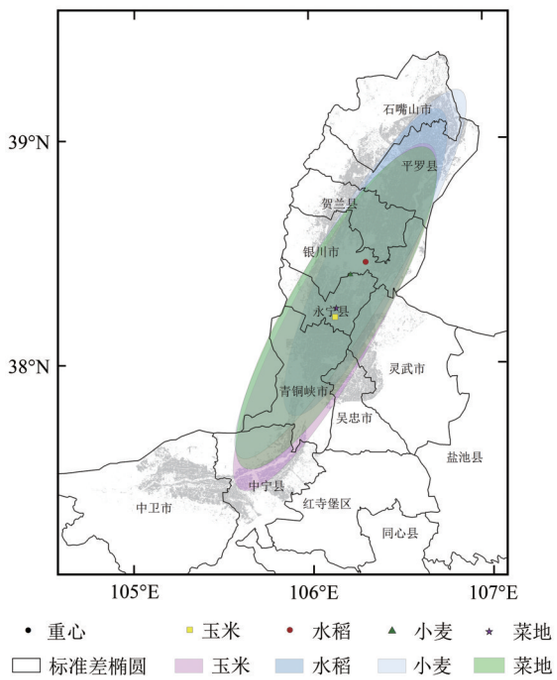
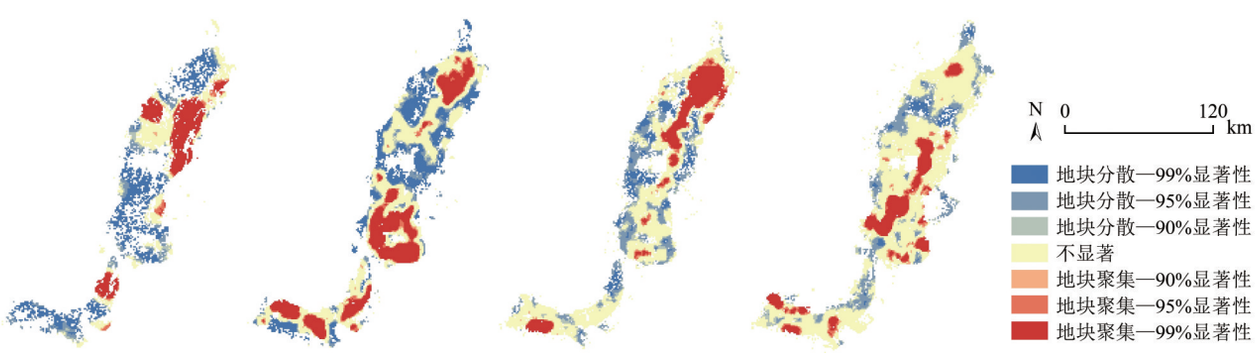


图15　研究区3种粮食作物标准差椭圆及重心

Fig. 15　Standard deviational ellipse and center of gravity migration of three kinds of food crops in the study area



（a）水稻　（b）玉米　（c）小麦　（d）菜地

（a）Rice　（b）Maize　（c）Crop　（d）Vegetable

图16　研究区4种主要作物显著性热点和冷点的空间聚类模式

Fig. 16　Spatial clustering patterns of significant hot spots and cold spots for four major crops in the study area

5　讨　论

本文从摸清农作物准确的种植面积与精细的空间分布的问题驱动出发，利用获取成本低、覆盖范围大的遥感影像，设计了时空协同的种植结构精细提取方法，技术流程清晰可复现，为大范围的、地块尺度的作物分布遥感提取提供了实用化的解决方案。

在未来还有以下两个方面可以深入研究：

（1）本文在地块尺度上对主要粮食作物和主要经济作物进行分类提取，满足种植结构空间分布研究的需求，但对于小宗作物关注较少。宁夏引黄灌区的枸杞、向日葵等种植面积较小的特色经济作物地块破碎、分布分散，下一步可考虑根据此类作物独特的空间、光谱、时间变异性，优化种植结构提取模型，增加作物上图的类型和数量。

（2）此外，时间结构也是作物种植结构的另一重要方面，本研究利用2020年作物生长期内的多时相遥感数据，获取一年度的农作物空间分布信息，这种方法对时效性要求不高。为满足农业实时监测，今后考虑从时间维度寻找不同作物的最优识别点，执行增量训练过程，建立农作物生长早期、关键生育期等动态变化的农作物空间分布数据集，以达到提高农作物遥感制图的时效性。

6 结 论

针对农业管理对精准种植结构信息的现实需求，本文综合高空间和高时间分辨率遥感数据的互补优势，发展了一种时空协同的种植结构遥感制图方法。以从高分影像提取的农田地块作为基本单元，结合高时间分辨率遥感影像，构建了地块尺度上的NDVI时间序列数据集，并通过Bi-LSTM实现了作物类型的精准分类，得到了宁夏引黄灌区种植结构信息，进而分析了研究区主要作物的空间分布特征，以及NDVI时序曲线的物候响应特征。结合一系列的实验对比分析，得到以下结论：

（1）相比于传统的制图单元，在对耕地类型的预测中，以地块为最小制图单元，具有较大的分类精度优势和更好的分类效果。从高分影像上获取的耕地地块形态完整，耕地的边界信息准确，与实际的耕地形态更加贴合。其制图结果与实际的农业耕作管理单元相对应，满足了地图使用者对作物专题图精准感知的需求。

（2）基于NDVI时间序列数据和Bi-LSTM网络进行作物分类，能够将时间序列特征的上下文信息考虑在内，解决了传统的分类方法主观性较强的问题，是实现作物类型提取的有效手段。模型对水稻、玉米、菜地等物候特征明显的作物分类效果最好，对于小麦单种和小麦复种类型则降低了错分率与漏分率。

（3）种植结构提取结果表明：1）玉米、水稻、小麦和蔬菜是研究区的主要作物。玉米种植面积最大，空间分布最广泛。2）菜地主要集中分布在永宁县和青铜峡市。3）水稻和小麦的种植面积相差不大，但是空间分布特征具有较强的地域性，水稻集中在灌溉便利的区域，小麦分布较为分散。4）小麦复种夏季作物主要集中在贺兰县、银川市、永宁县和青铜峡市，小麦的复种指数由南向北逐渐降低。

参考文献（References）

Ashourloo D, Shahrabi H S, Azadbakht M, Aghighi H, Nematollahi H, Alimohammadi A and Matkan A A. 2019. Automatic canola mapping using time series of sentinel 2 images. ISPRS Journal of Photogrammetry and Remote Sensing, 156: 63-76 [DOI: 10.1016/j.isprsjprs.2019.08.007]

Bazzi H, Baghdadi N, El Hajj M, Zribi M, Minh D H T, Ndikumana E, Courault D and Belhouchette H. 2019. Mapping paddy rice using Sentinel-1 SAR time series in Camargue, France. Remote Sensing, 11(7): 887 [DOI: 10.3390/rs11070887]

Becker-Reshef I, Justice C, Sullivan M, Vermote E, Tucker C, Anyamba A, Small J, Pak E, Masuoka E, Schmaltz J, Hansen M, Pittman K, Birkett C, Williams D, Reynolds C and Doorn B. 2010. Monitoring global croplands with coarse resolution earth observations: the Global Agriculture Monitoring (GLAM) project. Remote Sensing, 2(6): 1589-1609 [DOI: 10.3390/rs2061589]

Belgiu M and Csillik O. 2018. Sentinel-2 cropland mapping using pixel-based and object-based time-weighted dynamic time warping analysis. Remote Sensing of Environment, 204: 509-523 [DOI: 10.1016/j.rse.2017.10.005]

Chauhan S, Darvishzadeh R, Boschetti M, Pepe M and Nelson A. 2019. Remote sensing-based crop lodging assessment: current status and perspectives. ISPRS Journal of Photogrammetry and Remote Sensing, 151: 124-140 [DOI: 10.1016/j.isprsjprs.2019.03.005]

Chen S B and Sun J L. 1997. Key technical links and solution ways of setting up a working system for yield estimations of the main crops of China by satellite remote sensing. Journal of Natural Resources, 12(4): 363-369 (陈沈斌, 孙九林. 1997. 建立我国主要农作物卫星遥感估产运行系统的主要技术环节及解决途径. 自然资源学报, 12(4): 363-369)

Derenyi E. 1979. A small crop information system//Proceedings of Remote Sensing for Natural Resources.

Dronova I, Gong P, Clinton N E, Wang L, Fu W, Qi S H and Liu Y. 2012. Landscape analysis of wetland plant functional types: the effects of image segmentation scale, vegetation classes and classification methods. Remote Sensing of Environment, 127: 357-369 [DOI: 10.1016/j.rse.2012.09.018]

Duveiller G, Weiss M, Baret F and Defourny P. 2011. Retrieving wheat Green Area Index during the growing season from optical time series measurements based on neural network radiative transfer inversion. Remote Sensing of Environment, 115(3): 887-896 [DOI: 10.1016/j.rse.2010.11.016]

Fritz S, See L, Bayas J C L, Waldner F, Jacques D, Becker-Reshef I, Whitcraft A, Baruth B, Bonifacio R, Crutchfield J, Rembold F, Rojas O, Schucknecht A, Van Der velde M, Verdin J, Wu B F, Yan

N N, You L Z, Gilliams S, Mücher S, Tetrault R, Moorthy I and Mccallum I. 2019. A comparison of global agricultural monitoring systems and current gaps. Agricultural Systems, 168: 258-272 [DOI: 10.1016/j.agsy.2018.05.010]

Hao P Y, Zhan Y L, Wang L, Niu Z and Shakir M. 2015. Feature selection of time series MODIS data for early crop classification using Random Forest: a case study in Kansas, USA. Remote Sensing, 7(5): 5347-5369 [DOI: 10.3390/rs70505347]

Hochreiter S and Schmidhuber J. 1997. Long short-term memory. Neural Computation, 9(8): 1735-1780 [DOI: 10.1162/neco.1997.9.8.1735]

Khanal S, Fulton J and Shearer S. 2017. An overview of current and potential applications of thermal remote sensing in precision agriculture. Computers and Electronics in Agriculture, 139: 22-32 [DOI: 10.1016/j.compag.2017.05.001]

Liu J W, Chen P F, Zhang D Y and Zhao H W. 2020. Crop planting structure in Lishu County based on time-series Sentinel-2 images. Jiangsu Journal of Agricultural Sciences, 36(6): 1428-1436 (刘俊伟, 陈鹏飞, 张东彦, 赵红伟. 2020. 基于时序Sentinel-2影像的梨树县作物种植结构. 江苏农业学报, 36(6): 1428-1436) [DOI: 10.3969/j.issn.1000-4440.2020.06.011]

Liu W, Wang J, Luo J C, Wu Z F, Chen J D, Zhou Y N, Sun Y W, Shen Z F, Xu N and Yang Y P. 2020. Farmland parcel mapping in mountain areas using time-Series SAR data and VHR optical images. Remote Sensing, 12(22): 3733 [DOI: 10.3390/rs12223733]

Liu W, Wu Z F, Luo J C, Sun Y W, Wu T J, Zhou N, Hu X D, Wang L Y and Zhou Z F. 2021. A divided and stratified extraction method of high-resolution remote sensing information for cropland in hilly and mountainous areas based on deep learning. Acta Geodaetica et Cartographica Sinica, 50(1): 105-116 (刘巍, 吴志峰, 骆剑承, 孙营伟, 吴田军, 周楠, 胡晓东, 王玲玉, 周忠发. 2021. 深度学习支持下的丘陵山区耕地高分辨率遥感信息分区分层提取方法. 测绘学报, 50(1): 105-116) [DOI: 10.11947/j.AGCS.2021.20190448]

Liu Y, Cheng M M, Hu X W, Bian J W, Zhang L, Bai X and Tang J H. 2019. Richer convolutional features for edge detection. IEEE Transactions on Pattern Analysis and Machine Intelligence, 41(8): 1939-1946 [DOI: 10.1109/TPAMI.2018.2878849]

Ma L, Liu Y, Zhang X L, Ye Y X, Yin G F and Johnson B A. 2019. Deep learning in remote sensing applications: a meta-analysis and review. ISPRS Journal of Photogrammetry and Remote Sensing, 152: 166-177 [DOI: 10.1016/j.isprsjprs.2019.04.015]

Pelletier C, Webb G and Petitjean F. 2019. Temporal convolutional neural network for the classification of satellite image time series. Remote Sensing, 11(5): 523 [DOI: 10.3390/rs11050523]

Punalekar S M, Verhoef A, Quaife T L, Humphries D, Bermingham L and Reynolds C K. 2018. Application of Sentinel-2A data for pasture biomass monitoring using a physically based radiative transfer model. Remote Sensing of Environment, 218: 207-220 [DOI: 10.1016/j.rse.2018.09.028]

Shen Z F, Luo J C, Hu X D and Sun W G. 2010. A mean shift multi-scale segmentation for high-resolution remote sensing images. Geomatics and Information Science of Wuhan University, 35(3): 313-316 (沈占锋, 骆剑承, 胡晓东, 孙卫刚. 2010. 高分辨率遥感影像多尺度均值漂移分割算法研究. 武汉大学学报(信息科学版), 35(3): 313-316) [DOI: 10.13203/j.whugis2010.03.009]

Shi Z, Liang Z Z, Yang Y Y and Guo Y. 2015. Status and prospect of agricultural remote sensing. Transactions of the Chinese Society for Agricultural Machinery, 46(2): 247-260 (史舟, 梁宗正, 杨媛媛, 郭燕. 2015. 农业遥感研究现状与展望. 农业机械学报, 46(2): 247-260) [DOI: 10.6041/j.issn.1000-1298.2015.02.037]

Song G and Zhang W Q. 2020. Spatiotemporal differentiation characteristics of cultivated land use from persprctive of growing food crops in major grain production areas in northeast China. Transactions of the Chinese Society of Agricultural Engineering, 36(15): 1-8 (宋戈, 张文琦. 2020. 粮食作物种植视角下东北粮食主产区耕地利用的时空分化特征. 农业工程学报, 36(15): 1-8) [DOI: 10.11975/j.issn.1002-6819.2020.15.001]

Sonobe R. 2019. Parcel-based crop classification using multi-temporal TerraSAR-X dual polarimetric data. Remote Sensing, 11(10): 1148 [DOI: 10.3390/rs11101148]

Steinhausen M J, Wagner P D, Narasimhan B and Waske B. 2018. Combining Sentinel-1 and Sentinel-2 data for improved land use and land cover mapping of monsoon regions. International Journal of Applied Earth Observation and Geoinformation, 73: 595-604 [DOI: 10.1016/j.jag.2018.08.011]

Sun Y W, Luo J C, Wu T J, Zhou Y, Liu H, Gao L J, Dong W, Liu W, Yang Y P, Hu X D, Wang L Y and Zhou Z F. 2019. Synchronous response analysis of features for remote sensing crop classification based on optical and SAR time-series data. Sensors (Basel), 19(19): 4227 [DOI: 10.3390/s19194227]

Tan S, Wu B F and Zhang X. 2019. Mapping paddy rice in the Hainan Province using both Google Earth Engine and remote sensing images. Journal of Geo-Information Science, 21(6): 937-947 (谭深, 吴炳方, 张鑫. 2019. 基于Google Earth Engine与多源遥感数据的海南水稻分类研究. 地球信息科学学报, 21(6): 937-947) [DOI: 10.12082/dqxxkx.2019.180423]

Vuolo F, Neuwirth M, Immitzer M, Atzberger C and Ng W T. 2018. How much does multi-temporal Sentinel-2 data improve crop type classification? International Journal of Applied Earth Observation and Geoinformation, 72: 122-130 [DOI: 10.1016/j. jag. 2018.06.007]

Wang H J, Zhang B, Liu Y L, Liu Y F, Xu S, Deng Y, Zhao Y T, Chen Y C and Hong S. 2018. Multi-dimensional analysis of urban expansion patterns and their driving forces based on the center of gravity-GTWR model: a case study of the Beijing-Tianjin-Hebei urban agglomeration. Acta Geographica Sinica, 73(6): 1076-1092 (王海军, 张彬, 刘耀林, 刘艳芳, 徐姗, 邓羽, 赵雲泰, 陈宇琛, 洪松. 2018. 基于重心-GTWR模型的京津冀城市群城镇扩展格局与驱动力多维解析. 地理学报, 73(6): 1076-1092) [DOI: 10.11821/dlxb201806007]

Wang H Y, Zhao X, Zhang X, Wu D H and Du X Z. 2019. Long time series land cover classification in China from 1982 to 2015 based

on Bi-LSTM deep learning. Remote Sensing, 11(14): 1639 [DOI: 10.3390/rs11141639]

Wang Y Q, Bai Y R and Zhan X L. 2014. Spatial variability of soil nutrients at different sampling scales in farmland in the Yellow River irrigated area in Ningxia. Arid Zone Research, 31(2): 209-215 (王幼奇, 白一茹, 展秀丽. 2014. 在不同尺度下宁夏引黄灌区农田土壤养分空间变异分析. 干旱区研究, 31(2): 209-215) [DOI: 10.13866/j.azr.2014.02.019]

Weiss M, Jacob F and Duveiller G. 2020. Remote sensing for agricultural applications: a meta-review. Remote Sensing of Environment, 236: 111402 [DOI: 10.1016/j.rse.2019.111402]

Wu B F, Meng J H, Li Q Z, Yan N N, Du X and Zhang M. 2014. Remote sensing-based global crop monitoring: experiences with China's CropWatch system. International Journal of Digital Earth, 7 (2): 113-137 [DOI: 10.1080/17538947.2013.821185]

Wu B F, Zhang M, Zeng H W, Zhang X, Yan N N and Meng J H. 2016. Agricultural monitoring and early warning in the era of big data. Journal of Remote Sensing (in Chinese), 20(5): 1027-1037 (吴炳方, 张森, 曾红伟, 张鑫, 闫娜娜, 蒙继华. 2016. 大数据时代的农情监测与预警. 遥感学报, 20(5): 1027-1037) [DOI: 10.11834/jrs.20166248]

Wu T J, Dong W, Luo J C, Sun Y W, Huang Q T, Wu W Z and Hu X D. 2019. Geo-parcel-based geographical thematic mapping using C5.0 decision tree: a case study of evaluating sugarcane planting suitability. Earth Science Informatics, 12(1): 57-70 [DOI: 10.1007/s12145-018-0360-8]

Wu Z F, Luo J C, Sun Y W, Wu T J, Cao Z, Liu W, Yang Y P and Wang L Y. 2020. Research on precision agricultural based on the spatial-temporal remote sensing collaboration. Journal of Geo-Information Science, 22(4): 731-742 (吴志峰, 骆剑承, 孙营伟, 吴田军, 曹峥, 刘巍, 杨颖频, 王玲玉. 2020. 时空协同的精准农业遥感研究. 地球信息科学, 22(4): 731-742) [DOI: 10.12082/dqxxkx.2020.190726]

Xu N, Luo J C, Zuo J, Hu X D, Dong J, Wu T J, Wu S L and Liu H. 2020. Accurate suitability evaluation of large-scale roof greening based on RS and GIS methods. Sustainability, 12(11): 4375 [DOI: 10.3390/su12114375]

Yang Y P, Huang Q T, Wu W, Luo J C, Gao L, Dong W, Wu T J and Hu X D. 2017. Geo-parcel based crop identification by integrating high spatial-temporal resolution imagery from multi-source satellite data. Remote Sensing, 9(12): 1298 [DOI: 10.3390/rs9121298]

Ye W F, Ma Z Y and Ha X Z. 2018. Spatial-temporal patterns of $PM_{2.5}$ concentrations for 338 Chinese cities. Science of the Total Environment, 631-632: 524-533 [DOI: 10.1016/j.scitotenv.2018.03.057]

Zhao C J. 2014. Advances of research and application in remote sensing for agriculture. Transactions of the Chinese Society for Agricultural Machinery, 45(12): 277-293 (赵春江. 2014. 农业遥感研究与应用进展. 农业机械学报, 45(12): 277-293) [DOI: 10.6041/j.issn.1000-1298.2014.12.041]

Zhao H W, Chen Z X, Jiang H, Jing W L, Sun L and Feng M. 2019. Evaluation of three deep learning models for early crop classification using Sentinel-1A imagery time series—A case study in Zhanjiang, China. Remote Sensing, 11(22): 2673 [DOI: 10.3390/rs11222673]

Zhao R K, Li Y C and Ma M G. 2021. Mapping paddy rice with satellite remote sensing: a review. Sustainability, 13(2): 503 [DOI: 10.3390/su13020503]

Zhou Y N, Luo J C, Feng L, Yang Y P, Chen Y H and Wu W. 2019. Long-short-term-memory-based crop classification using high-resolution optical images and multi-temporal SAR data. GIScience and Remote Sensing, 56(8): 1170-1191 [DOI: 10.1080/15481603.2019.1628412]

Zhu X X, Tuia D, Mou L C, Xia G S, Zhang L P, Xu F and Fraundorfer F. 2017. Deep learning in remote sensing: a comprehensive review and list of resources. IEEE Geoscience and Remote Sensing Magazine, 5(4): 8-36 [DOI: 10.1109/mgrs.2017.2762307]

Precise crop planting structure mapping method based on spatial−temporal collaboration of remote sensing

ZHANG Dongyun[1,2], WU Tianjun[3], LUO Jiancheng[1,2], DONG Wen[1,2], SUN Yingwei[4], YANG Yingpin[5], HAI Yunrui[6], MENG Bowen[2], LIU Wei[1,2]

1. Key Laboratory of Remote Sensing and Digital Earth, Aerospace Information Research Institute, Chinese Academy of Sciences, Beijing 100101, China;

2. University of Chinese Academy of Sciences, Beijing 100049, China;

3. School of Land Engineering, Chang'an University, Xi'an 710064, China;

4. Institute of Agricultural Resources and Regional Planning, Chinese Academy of Agricultural Sciences, Beijing 100081, China;

5. School of Geography and Remote Sensing, Guangzhou University, Guangzhou 510006, China;

6. Institute of Agricultural Economy and Information Technology, Ningxia Academy of Forestry Sciences, Yinchuan 750000, China

Abstract: Agriculture is an important component of the national economy. Obtaining the spatial distribution information of crops

accurately is the basis of precision agricultural application. In this paperstudy , we explore the complementary advantages of remote sensing data from different sources in terms of spatial and temporal characteristics, and. We also design a remote sensing mapping method of agricultural planting structure based on spatial and temporal collaboration. The cropland-parcel extracted from high spatial resolution remote sensing images of high spatial resolution was is taken as the basic unit, and the spectral time sequence information of multi-temporal remote sensing images was is combined. With the support of deep learning, crop classification and identification at cropland-parcel scale and precise mapping of planting structure can be realized, and the spatial distribution characteristics of main crops can be analyzed. The eExperimental results in Yellow River Irrigation Area of Ningxia (YRIA-NX) show that: (1) A a total of 1.49 million cropland-parcels were are obtained in the study area, with a total area of about 540,000 hm^2, and the overall classification accuracy was is 0.80; (2) Compared with the traditional mapping unit and machine learning method, the crop planting structure information obtained by the Bi-LSTM network based on the cropland-parcel scale is more consistent with the actual agricultural tillage management unit, and the classification accuracy can be guaranteed higher; (3) The maize, rice, wheat, and vegetables are the main crops of in the study area. Maize is the most dominant crop with the largest planting area and the most extensive spatial distribution. The vegetable fields are mainly concentrated and distributedion in Yongning Town and Qingtongxia Town. Rice is concentrated in areas with convenient irrigation, while wheat planting area on a large scale is less. The planting of other crops after wheat harvest in summer is mainly concentrated in the Qingtongxia, and the multiple cropping index decreasesd gradually from south to north.

Key words: remote sensing, crop planting structure, spatial-temporal collaboration, deep learning, cropland-parcel, NDVI time series, Yellow River Irrigation Area of Ningxia (YRIA-NX)

Supported by National Natural Science Foundation of China (No. 42071316); National Key Research and Development Program (No. 2021YFB3900905)