基于 GF-1 WFV 数据的玉米与大豆种植面积提取方法

黄健熙，侯裔焯，苏 伟，刘峻明，朱德海
（中国农业大学信息与电气工程学院，北京 100083）

摘 要：准确掌握农作物的空间种植分布情况，对于国家宏观指导农业生产、制定农业政策有重要意义。针对黑龙江省玉米与大豆生育期接近、光谱特征相似，较难区分的问题，以多时相 16 m 空间分辨率高分一号（GF-1）卫星宽覆盖（wide field of view, WFV）影像为数据源，选择归一化植被指数（normalized difference vegetation index, NDVI）、增强植被指数（enhanced vegetation index, EVI）、宽动态植被指数（wide dynamic range vegetation index, WDRVI）、归一化水指数（normalized difference water index, NDWI）4 个特征，结合实地调查样本点，采用随机森林分类算法，提取黑龙江省黑河市嫩江县玉米与大豆种植面积。研究表明，区分玉米与大豆的最佳时段为 9 月下旬至 10 月上旬，即大豆已收获而玉米未收获的时段，在 4 个待选特征中，NDVI、NDWI 与 WDRVI 指数组合表现最佳；随机森林算法与最大似然算法、支持向量机算法相比，分类精度更高，其总体分类精度为 84.82%，Kappa 系数为 77.42%。玉米制图精度为 91.49%，用户精度为 93.48%；大豆制图精度为 91.14%，用户精度为 82.76%。该方法为大区域农作物的分类提供重要参考和借鉴价值。

关键词：遥感；提取；分类；随机森林；大豆；玉米
doi：10.11975/j.issn.1002-6819.2017.07.021
中图分类号：TP79; S127 **文献标志码**：A **文章编号**：1002-6819(2017)-07-0164-07

黄健熙，侯裔焯，苏 伟，刘峻明，朱德海. 基于 GF-1 WFV 数据的玉米与大豆种植面积提取方法[J]. 农业工程学报，2017，33(7)：164－170. doi：10.11975/j.issn.1002-6819.2017.07.021 http://www.tcsae.org
Huang Jianxi, Hou Yuzhuo, Su Wei, Liu Junming, Zhu Dehai. Mapping corn and soybean cropped area with GF-1 WFV data[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2017, 33(7): 164－170. (in Chinese with English abstract) doi：10.11975/j.issn.1002-6819.2017.07.021 http://www.tcsae.org

0 引 言

掌握农作物的空间种植分布状况，对于宏观指导农业生产、合理采取农作物管理措施具有重要的现实意义，同时也为农情监测的提供了重要基础数据。而传统的农业统计报表和抽样调查，通常耗费大量人力物力，并且持续时间长，作业效率不高。遥感技术为大区域农作物种植面积提取提供了有效的技术手段，国内外学者从遥感数据源、分类方法等角度，对此进行了大量的研究。

植被指数能够反映植物生长状况，利用卫星不同的波段数据组合而成，以高分一号（GF-1）卫星[1-2]、HJ-1 A/B 卫星[3-5]或者 Landsat 卫星[6-7]为数据源，利用时间序列影像获取分类特征，精度较高，因此考虑利用时序植被指数影像等获取玉米与大豆的光谱特征进行分类。与 30 m 空间分辨率、16 d 重访周期的 Landsat8 OLI 卫星相比，国产 GF-1 卫星 16 m 空间分辨率宽覆盖(wide field of view, WFV)空间和时间分辨率（4 d）都较高，能够获得满足玉米与大豆识别的关键生育期影像。因此，本文选择 GF-1 卫星作为遥感数据源。常用的分类算法，例如支持向量机（support vector machine，SVM）[4]、最大似然方法（maximum likelihood, ML）[8]、决策树[9]等区分玉米与大豆，识别精度并不高。这是由于选用的分类指标如归一化植被指数（normalized difference vegetation index，NDVI）较为单一，难以有效区分玉米与大豆，另一方面是因为分类器在获取有效分类特征方面存在局限性。王利民等[10]基于 Landsat-8 OLI 数据，从短波红外重要性的角度，利用最大似然方法，区分玉米与大豆种植面积，但 Landsat-8 卫星较长的回访周期限制了关键生育期影像的获取。陈思宁等[11-14]的研究针对玉米与大豆两者的区分、单独提取玉米或大豆，结合当地作物物候、地形等特点，利用作物波段特点、回归树或者波谱角分类（spectral angle mapper，SAM）分类器等进行分类提取，精度较好。但是国外学者研究区多选择为巴西等大片单一作物种植地，降低了区分二者的难度。Hao 等[15]研究了时间序列 MODIS 数据中特征的选择对于分类的影响，时间序列数据中覆盖作物关键生育期即 7 月和 8 月的时相最为重要。利用 MODIS 数据[15-20]与 MODIS NDVI、MODIS EVI 产品[20-24]进行大区域范围内的作物分类，均采用多时相数据使用不同的方法进行作物识别，精度较高。

黑龙江省种植的玉米与大豆生育期接近，光谱信息相似，利用遥感数据原始光谱波段难以进行区分，并且存在玉米与大豆混种的现象，加大了区分难度。近年来，随机森林算法得到广泛应用。随机森林（random forest，RF）分类器由 Breiman 提出[25]，是一种自然的非线性建模工具。随机森林基于统计学习理论，采用 bootstrap 重抽样方法从原始训练集中选取多个样本，且每个样本的

收稿日期：2016-10-06 修订日期：2017-04-11
基金项目：国家自然科学基金资助 (41671418, 41471342,41371326)
作者简介：黄健熙，男，副教授，博士，博士生导师，主要从事定量遥感等研究。北京 中国农业大学信息与电气工程学院，100083.
Email：jxhuang@cau.edu.cn

样本容量与原始训练集中一样，进而对每个选取的样本建立相应的决策树模型，最终组合多棵决策树的预测结果进行投票判断。随机森林预测准确率高，对异常值和噪声具有很好的容忍度，并且不容易出现过拟合[26]。Ghosh 等[27]在随机森林提取等方面对 Landsat 数据进行分析得到了较理想的效果，刘毅等[28]也比较了多种方法发现随机森林是精度最高的一种方法。然而，RF 方法对玉米和大豆的有效区分是否适用仍然是一个需要探索的问题。本文采用随机森林算法区分玉米和大豆，并给出最优的区分时段。

1　研究区与试验数据

1.1　研究区概况

本文研究区选择为黑龙江省黑河市嫩江县，位于黑龙江省西北部，地跨 124°44′30″～126°49′30″E，48°42′35″～51°00′05″N，面积超过 15 000 km^2，且县内地物类型分布较为复杂，增大了分类难度。如图 1 所示，嫩江县底图为高分一号真彩色图像。嫩江县包括九三农场管理局所属的绝大部分农场，属中温带半湿润大陆季风气候，年平均无霜期 80～130 d，雨热同季，年日照 2 728.2 h，年平均气温 0.4 ℃左右，全县从南至北积温在 2 500～1 600 ℃之间，光照充足，适合多种作物生长。多年平均降水量为 500 mm，县内河流属嫩江水系。

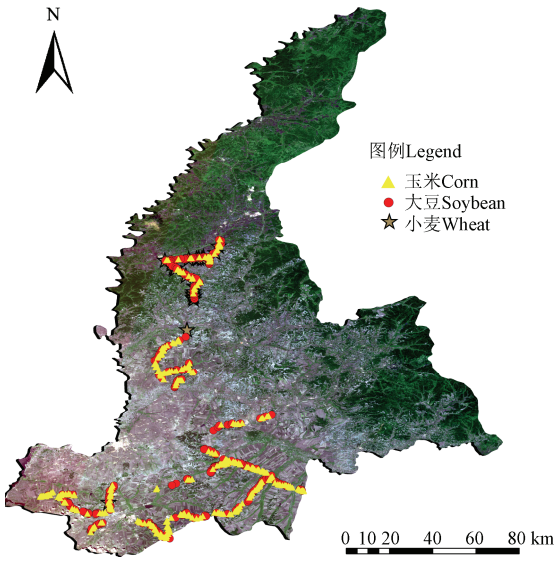


图 1　研究区样本点分布示意图

Fig.1　Location of sampling points in study area

在正常年份，玉米于 4 月 25 日至 30 日播种，5 月 15 日至 20 日出苗，6 月 15 日至 20 日拔节，7 月 10 日至 15 日抽雄，成熟于 9 月 10 日至 15 日，收获于 10 月中下旬；在嫩江县北部的农场，大豆于阳历 5 月 15 日至 20 日播种，南部的农场播种日期则在 4 月末，10 d 左右出苗，经过 90 至 110 d 后，大豆成熟，收获于 9 月中旬。

嫩江县土地肥沃，适宜大豆、小麦、玉米、甜菜、马铃薯等作物生长，是农牧生产的黄金地带，中国著名的麦、豆生产基地，国家重要的商品粮食生产基地，中国“大豆之乡”。只有少量的水稻种植，因此是研究大豆、玉米作物面积提取的理想研究区。

1.2　GF-1 WFV 时间序列数据集

高分一号(GF-1)卫星搭载的 4 台多光谱相机(WFV)幅宽可达 800 km，包括蓝（0.45～0.52 μm）、绿（0.52～0.59 μm）、红（0.63-0.69 μm）、近红外（0.77～0.89 μm）4 个波段，空间分辨率达到 16 m，重访周期为 2 d，同时具有较高空间和时间分辨率的特点，能获取无云的作物关键生育期的遥感影像。考虑到所选影像应该在同一天内覆盖嫩江县，且影像应该无云或少云，因此选取在玉米、大豆、小麦等主要种植作物生长季（2015 年 4 月至 9 月）的 7 个时相的遥感数据[15]，分别为 2015 年 4 月 14 日、2015 年 5 月 20 日、2015 年 6 月 26 日、2015 年 7 月 16 日、2015 年 8 月 26 日、2015 年 9 月 4 日、2015 年 9 月 29 日。

影像的预处理包括辐射定标、大气校正和几何校正、拼接裁剪。大气校正模型采用 6S（second simulation of the satellite signal in the solar spectrum）模型，得到真实地表反射率数据，可以用于作物分类研究。几何校正是先采用影像自带 RPC（rational polynomial coefficient）文件进行正射校正，再以同时期 Landsat-8 影像为基准进行几何精校正，最终获得 GF-1 WFV 时间序列数据集。

1.3　实地调查数据

为获取黑龙江省黑河市嫩江县主要地物类型的分布，2015 年 9 月对嫩江县进行地面实地调查（图 1）。野外调查时采用手持 GPS（global positioning system）测量特征地块的经纬度坐标并记录植被类型、拍摄照片，调查路线覆盖嫩江县绝大部分农场，农场外农田中也有少量样本点被采集，而嫩江县北部为伊勒呼里山、东部为小兴安岭，多为林地，故没有在此采集样本点。此次调查共获取样本点 757 个，其中玉米 315 个，大豆 264 个，小麦 23 个，其他植被 113 个，建设用地 28 个，水体 14 个。

依据研究区主要作物种植情况结合野外调查数据，在嫩江县极少有水稻分布，因此水稻不单独作为提取作物中的一类。此外，实地调查还发现有零星分布种植的蔬菜水果等，本研究中将其与林地、荒草、瓜果、高粱等归为其他植被一类。因此分类类别包括大豆、玉米、小麦、其他植被、建设用地、水体共 6 类。

2　作物分类

将选取的黑龙江省黑河市嫩江县多时相 GF-1 WFV 影像进行预处理，计算特征变量后产生特征变量数据集，结合训练样本集输入随机森林分类器中进行分类识别，在分类器中进行多棵决策树的构建并且对结果进行投票得出最后分类结果，然后根据验证样本集进行精度评价。具体流程如图 2 所示。

2.1　特征指数数据集

由于玉米与大豆 2 种作物的光谱特征相似，因此不将原始数据波段作为待选分类特征。而根据黑龙江省黑河市嫩江县当地的作物种植结构以及已有遥感影像等，

选择能够检测植被绿度、植被覆盖度的 NDVI，具有校正土壤背景和气溶胶散射影响的增强植被指数（enhanced vegetation index，EVI），归一化水指数（normalized difference water index，NDWI）。其中计算公式（2）系数 G、C_1、C_2、L 根据文献[29]进行取值。此外，还选用了宽动态植被指数（wide dynamic range vegetation index，WDRVI），该指数中利用一个比重系数来缩小近红外波段和红波段对植被指数贡献之间的差距，研究表明比重系数取 0.2 时能够使得玉米和大豆的植被指数与其生物量有最优线性拟合，能有效区分玉米与大豆 2 种作物[14]，避免了 NDVI 等指数在 2 种作物上相近特征。

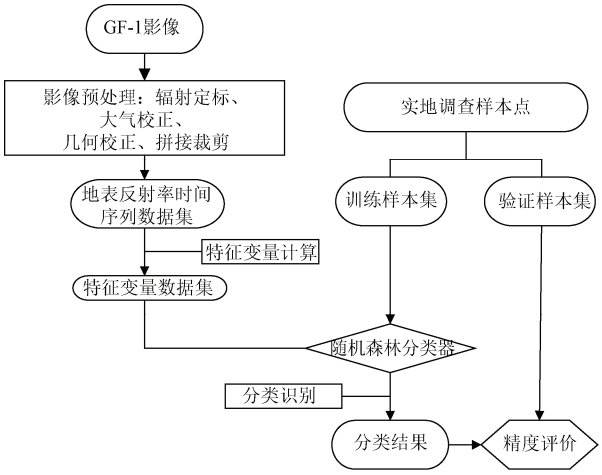


图 2 分类流程图

Fig.2 Flowchart of classification

根据预处理后得到的 GF-1 多光谱反射数据，计算 4 种指数，用其对嫩江县地区的主要农作物进行动态监测，计算公式如下。

$$\mathrm{NDVI}=\frac{\rho_{\mathrm{NIR}}-\rho_{\mathrm{RED}}}{\rho_{\mathrm{NIR}}+\rho_{\mathrm{RED}}} \tag{1}$$

$$\mathrm{EVI}=G\cdot\frac{\rho_{\mathrm{NIR}}-\rho_{\mathrm{RED}}}{\rho_{\mathrm{NIR}}+C_1\cdot\rho_{\mathrm{RED}}-C_2\cdot\rho_{\mathrm{BLUE}}+L} \tag{2}$$

$$\mathrm{NDWI}=\frac{\rho_{\mathrm{GREEN}}-\rho_{\mathrm{NIR}}}{\rho_{\mathrm{GREEN}}+\rho_{\mathrm{NIR}}} \tag{3}$$

$$\mathrm{WDRVI}=\alpha\cdot\frac{\rho_{\mathrm{NIR}}-\rho_{\mathrm{RED}}}{\rho_{\mathrm{NIR}}+\rho_{\mathrm{RED}}} \tag{4}$$

式中 ρ_{NIR}、ρ_{RED}、ρ_{BLUE}、ρ_{GREEN} 分别为近红外波段、红波段、蓝波段、绿波段的反射率；G 为增益因子，取值 2.5[29]；C_1、C_2 为气溶胶阻抗系数，取值 6 和 7.5[29]；C_1、C_2 为气溶胶阻抗系数，取值 6[29]和 7.5[29]；L 为冠层背景调整因子，取值 1[29]；α 为权重系数，取值 0.2[14]。

2.2 分类过程

将上述计算得到的 7 个时相的 4 种指数图像（共 28 景）叠加，已获取的 757 个地面调查点随机挑选，按照 7:3 的比例[30]将其分为训练样本点（533 个）与验证样本点（224 个），然后将待分类影像与训练样本点输入到随机森林分类器中，获得最终的分类结果。

3 结果与分析

3.1 典型地物时间序列变化分析

根据嫩江县主要作物的物候期特征以及典型地物时序变化图，玉米与大豆的播种期在 4 月末至 5 月中旬，在 5 月 20 日的影像中 NDVI、EVI 值较低，由于小麦于 3 月底播种，到 5 月 20 日时其值已经较高，可以将小麦有效区分。在图 3，根据 NDVI、EVI、WDRVI、NDWI 时序变化曲线可以看出玉米与大豆 2 种作物在 4~6 月变化趋势较为接近，在 7～9 月 4 种指数的值差异较大且变化趋势也不同，其中在 9 月 29 日 4 种指数的值差异最大，能够较好的区分玉米与大豆，这是因为大豆在 9 月 29 日已经完成收获，而玉米还未收获，玉米种植地的植被覆盖度快速降低而大豆种植地的植被覆盖度变化相对较小，表现为这 2 种作物在该时期的 NDVI、EVI 和 WDRVI 时序曲线值差异较大。而建设用地和水体 2 类时序曲线整体变化趋势比较稳定，与植被差异较大，其中水体在 NDVI 时序曲线图中表现为最低值而在 NDWI 时序曲线中表现为最高值，建设用地在 NDVI 时序曲线图中的值仅高于水体却低于植被，有利于区分水体、建设用地和植被。

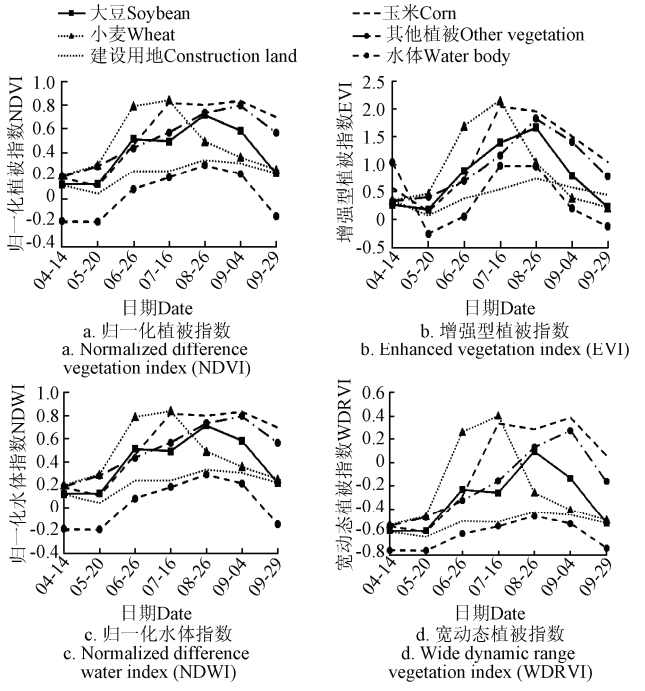


图 3 2015 年典型地物时序变化

Fig.3 Temporal changes of main crops in 2015

3.2 不同指数组合的分类精度对比

由图 3 可知由同一地物的光谱值计算得到的不同指数值有较大差异，为评估不同指数组合对分类精度的影响与贡献度，利用待选取的 NDVI、EVI、WDRVI、NDWI 共 4 个特征组合，分别进行分类提取，得到不同特征组合下的提取精度（图 4）。

由图 4 可以直观的看出，玉米与大豆 2 种作物的最佳区分特征为 NDVI、NDWI、WDRVI 3 者组合，且其总体分类精度在所有组合中也是最高的，大豆的用户精度

达到 82%、制图精度达到 94%，玉米的用户精度达到 92%、制图精度达到 89%。由图 4 中第 2～第 4 组合中可知，NDVI 分别与 EVI、NDWI、WDRVI 组合时并没有提高分类精度，如大豆的用户精度保持在 80%，这可能是因为 NDVI 能够较好地反映植被的绿度特征[2]，在此基础上再增加其他植被特征时会提高分类精度，如分类时在特征组合 NDVI、NDWI 的基础上增加 WDRVI 特征，大豆的制图精度提高了 5%。在图 4 最后 2 个组合即特征组合 NDVI、NDWI、EVI 和特征组合 NDVI、EVI、NDWI、WDRVI 中，由于 EVI 的加入降低了大豆的分类精度，这可能是因为 EVI 适用于植被茂密区，而大豆植株较为矮小并不适宜使用 EVI 获取特征信息[14]，加入分类器中反而会影像决策树的建立，因此 4 种特征组合时并没有提高 3 种待选特征组合时的提取精度。

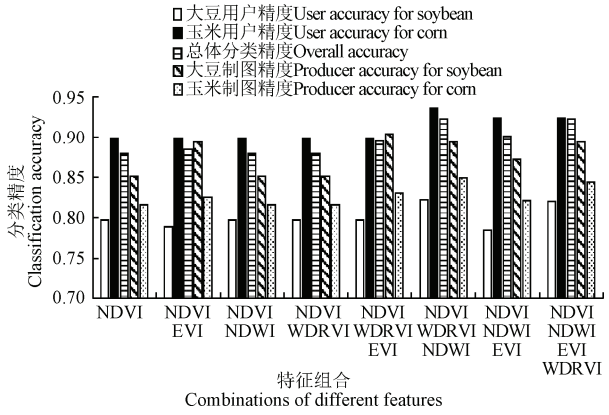


图 4　不同特征组合下的分类精度

Fig.4　Classification accuracy of combinations of different features

将 7 个时相的 GF-1 影像输入到随机森林分类器中，根据 NDVI、NDWI、WDRVI 3 种特征组合进行分类提取，获得嫩江县主要农作物分布图（图 5）。从图 5 中可以看出玉米与大豆多分布在嫩江县中部与西南部（多为国营农场所在地），北部也有少量分布，其中玉米种植面积多于大豆种植面积；图 5 中，其他植被类多分布在北部与东部，原因为嫩江县林地、荒草等多分布在嫩江县的北部与东部；小麦在嫩江县分布较为零散，与实地调查情况相符。

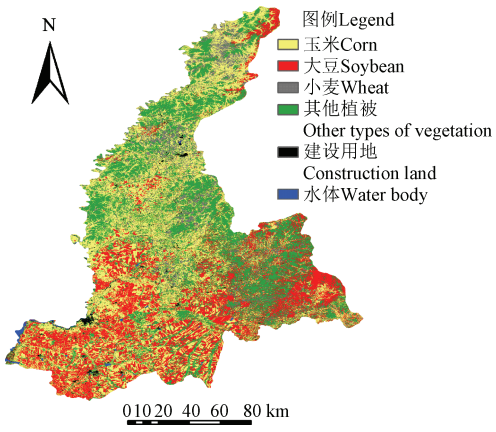


图 5　嫩江县分类结果

Fig.5　Classification results in Nenjiang County

本研究中以利用随机森林算法分类过程中确定的 222 个验证样本点对分类结果进行精度验证。验证样本点包括大豆 79 个、玉米 94 个、小麦 6 个、其他植被 31 个，建设用地 8 个，水体 4 个。各作物样本点提取精度结果如表 1 所示。

表 1　地物识别混淆矩阵

Table 1　Confusion matrix of crops identification

地块分类 Land classification	大豆 Soybean	玉米 Corn	小麦 Wheat	其他植被 Other types of vegetation	建设用地 Construction land	水体 Water body	合计 Total	用户精度 User accuracy/%
大豆 Soybean	72	6	1	8	0	0	87	82.76
玉米 Corn	2	86	0	4	0	0	92	93.48
小麦 Wheat	0	0	5	3	0	0	8	62.50
其他植被 Other types of vegetation	5	2	0	16	1	0	24	66.67
建设用地 Construction land	0	0	0	0	7	0	7	100.00
水体 Water body	0	0	0	0	0	4	4	100.00
地块合计 Total number of lands	79	94	6	31	8	4	222	/
制图精度 Producer accuracy/%	91.14	91.49	83.33	51.61	87.50	100.00	/	/

如表 1 所示，在所有验证样本点中，被正确分类的样本点有 190 个，总体样本精度为 84.82%，由计算式（5）计算得来的 Kappa 系数（Kappa coefficient）为 77.42%。玉米验证样本点共 94 个，被正确分类的样本点有 86 个；大豆验证样本点共 79 个，被正确分类的样本点为 72 个：玉米与大豆 2 类的训练样本点较多，其分类精度也较高，但是由于玉米与大豆播种时间相近，生育期中光谱特征等比较相似，因此玉米与大豆较难区分，也能够解释表中玉米与大豆错分的现象。小麦验证样本点共 6 个，被正确分类的样本点为 5 个：由于小麦样本点较少，能够放入分类器中的训练样本点也较少，没有充分的训练样本，随机森林分类器所得分类精度不高。其他植被类验证样本点共 31 个，被正确分类的样本点为 16 个：在其他植被类中，由于将林地、荒草、瓜果、高粱等都放入其中，光谱差异较大，会影响随机森林分类器中决策树的构建，分类精度自然较低，由此也可以解释其他植被类样本点中错分为其他作物的样本点也较多，其他作物中错分为其他植被类中的样本点也较多。建设用地验证样本点共 8 个，被正确分类的样本点为 7 个；水体验证样本点共 4 个，被正确分类的样本点为 4 个：对于建筑用地和水体 2 类，其光谱特征与植被差异很大，不同于小麦训练样本点数量少造成的分类精度较低，在其训练样本点数量较少的情况下仍能有效的与植被类进行区分，分类精度相对较高。

$$\text{Kappa}=\frac{P_o-P_e}{1-P_e}\times 100\% \quad (5)$$

式中 P_o 为实际一致率，P_e 为理论一致率[31]。

3.3 分类算法对比

为进一步验证本文所采用的随机森林算法的有效性，将随机森林算法分类结果与最大似然算法、SVM 算法分类结果进行对比分析。黑龙江九三农场管理局下大部分农场都位于嫩江县，选择位于嫩江县并且种植大量玉米与大豆 2 种作物的嫩江农场作为验证区，该农场位于嫩江县东南部，面积 489 km^2。

本研究利用与上文中相同的实地调查点信息，其中嫩江农场包括大豆样本点 52 个、玉米样本 67 个。以嫩江农场为验证区分别进行最大似然分类与 SVM 分类，分类结果如图 6 所示。图 7 为玉米与大豆样本个数统计。

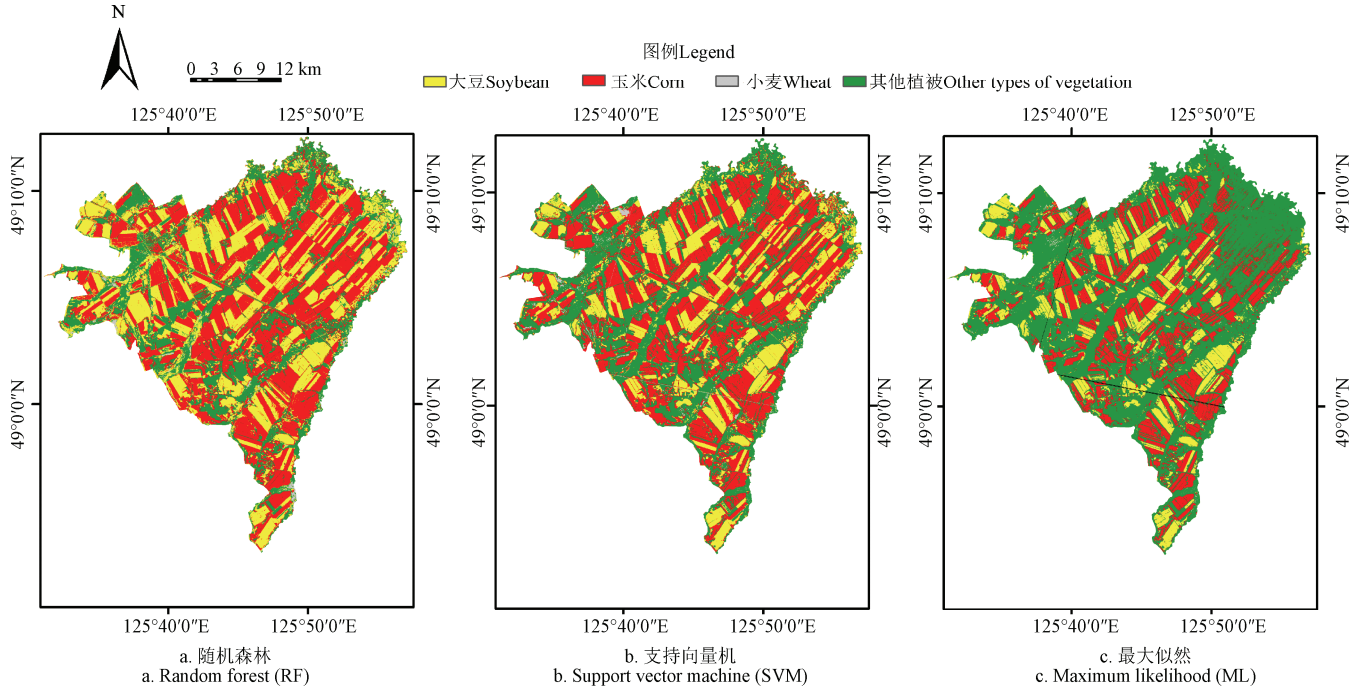


图 6 3 种分类算法分类结果

Fig.6 Classification results based on three methods

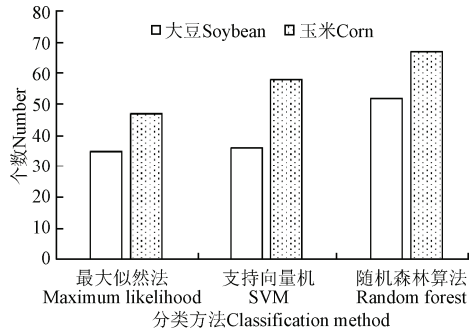


图 7 玉米与大豆样本个数统计

Fig.7 Statistic number of corn and soybean samples

从图 6 可以看出，随机森林算法、SVM 算法、最大似然算法 3 种算法中随机森林算法分类精度最高，表现为分类地块较为完整，并且能够分类出绝大部分农田。由图 6 和图 7 可知，随机森林算法将所有样本点所在种植区全部识别出来，效果最好；最大似然算法分类结果最差，与图 6 中结果一致。这是由于最大似然算法是一种基于统计的算法，通过计算样本间的似然度来判别像元是否归属于某一类，而在嫩江农场中玉米与大豆均有种植且分布不规律，其光谱特征等较为相似，增大了通过似然度判别地类的难度，结果较差；SVM 算法是建立在统计学习理论基础上的机器学习方法，其主要思想是在高维空间中寻找一个超平面作为 2 类的分割，与最大似然算法相比具有更多的学习过程，且分类结果优于最大似然分类，但是玉米与大豆 2 类作物相似的光谱特性依旧影响了 SVM 分类器分类精度。而随机森林算法通过构建多棵决策树进行投票决定最终分类结果，能够在一定程度上避免 1 次分类带来的误差，对于玉米和大豆 2 种作物的区分尤为有效，图 6 和图 7 也表明了这一点。

4 结 论

本文以 2015 年大豆、玉米生长季内的高分一号（GF-1）数据为数据源，以黑龙江省黑河市嫩江县为研究区，通过利用嫩江县主要作物的物候期，将归一化植被指数（normalized difference vegetation index，NDVI）等植被指数时序数据集、归一化水指数（normalized difference water index，NDWI）时序数据集、大量的实地调查样本点输入到随机森林分类器中进行决策树构建，提取了 2015 年的主要农作物的空间分布信息，得到以下结论：

1）采用随机森林分类器，嫩江县典型地物分类总体精度达到 84.82%，Kappa 系数达到 77.42%。

2）在黑龙江地区区分玉米和大豆的最优时间为 9 月

下旬至 10 月上旬，即大豆已收获而玉米未收获的时间。而在 4 个分类特征中，NDVI、NDWI 和 WDRVI 3 个特征组合在提取玉米与大豆 2 种作物时精度最高，NDVI 和 WDRVI 指数的贡献度最大。

3）与最大似然算法、SVM 算法相比，随机森林算法分类精度最高。但是高精度随机森林算法通常需要较多的训练样本和较长的模型训练时间。因此，在实际应用时需要综合考虑模型精度和执行效率。

［参　考　文　献］

[1] 黄健熙，贾世灵，武洪峰，等. 基于 GF-1 WFV 影像的作物面积提取方法研究[J]. 农业机械学报，2015(增刊 1)：253－259.
Huang Jianxi, Jia Shiling, Wu Hongfeng, et al. Extration method of crop planted area based on GF-1 WFV image[J]. Transactions of The Chinese Society for Agricultural Machinery, 2015(Supp.1): 253 － 259. (in Chinese with English abstract)

[2] 杨闫君，占玉林，田庆久，等. 基于 GF-1/WFVNDVI 时间序列数据的作物分类[J]. 农业工程学报，2015(24)：155－161.
Yang Yanjun, Zhan Yulin, Tian Qingjiu, et al. Crop classification based on GF-1/WFV NDVI time series[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2015(24): 155－161. (in Chinese with English abstract)

[3] 李鑫川，徐新刚，王纪华，等. 基于时间序列环境卫星影像的作物分类识别[J]. 农业工程学报，2013，29(2)：169－176.
Li Xinchuan, Xu Xingang, Wang Jihua, et al. Crop classification recognition based on time-series images from HJ satellite[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2013, 29(2): 169－176. (in Chinese with English abstract)

[4] 刘庆生，黄翀，刘高焕，等. 基于关键期 HJ 卫星数据提取无棣县作物种植面积[J]. 中国农学通报，2014，30(26)：284－290.
Liu Qingsheng, Huang Chong, Liu Gaohuan, et al. Planting area extraction of a crop key growth period in Wudi County based on HJ satellite data[J]. Chinese Agricultural Science Bulletin, 2014, 30(26): 284－290. (in Chinese with English abstract)

[5] 周静平，李存军，史磊刚，等. 基于决策树和面向对象的作物分布信息遥感提取[J]. 农业机械学报，2016，47(9)：318－326..
Zhou Jingping, Li Cunjun, Shi Leigang, et al. Crops distribution remote sensing extraction based on decision tree and object-oriented method[J]. Transactions of The Chinese Society for Agricultural Machinery, 2016, 47(9): 318－326. (in Chinese with English abstract)

[6] Dong Jinwei, Xiao Xiangming, Kou Weili, et al. Tracking the dynamics of paddy rice planting area in 1986-2010 through time series Landsat images and phenology-based algorithms[J]. Remote Sensing of Environment, 2015, 160: 99－113.

[7] Dong Jinwei, Xiao Xiangming, Menarguez M A., et al. Mapping paddy rice planting area in northeastern Asia with Landsat 8 images, phenology-based algorithm and Google Earth Engine[J]. Remote Sensing of Environment, 2016,185:142.

[8] 徐新刚，李强子，周万村，等. 应用高分辨率遥感影像提取作物种植面积[J]. 遥感技术与应用，2008，23(1)：17－23.
Xu Xingang, Li Qiangzi, Zhou Wancun, et al. Classification application of QuickBird imagery to obtain crop planting area[J]. Remote Sensing Technology and Application, 2008, 23(1): 17－23. (in Chinese with English abstract)

[9] 马丽，徐新刚，贾建华，等. 利用多时相 TM 影像进行作物分类方法[J]. 农业工程学报，2008，24(增刊 2)：191－195.
Ma Li, Xu Xingang, Jia Jianhua, et al. Crop classification method using multi-temporal TM images[J].Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2008, 24(Supp.2): 191－195. (in Chinese with English abstract)

[10] 王利民，刘佳，杨玲波，等. 短波红外波段对玉米大豆种植面积识别精度的影像[J]. 农业工程学报，2016，32(19)：169－178.
Wang Limin, Liu Jia, Yang Lingbo. Impact of short infrared wave band on identification accuracy of corn and soybean area[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2016, 32(19): 169－178. (in Chinese with English abstract)

[11] 陈思宁，赵艳霞，申双和. 基于波谱分析技术的遥感作物分类方法[J]. 农业工程学报，2012，28(5)：154－160.
Chen Sining, Zhao Yanxia, Shen Shuanghe. Crop classification by remote sensing based on spectral analysis[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2012, 288(5): 154－160. (in Chinese with English abstract)

[12] Maxwell S K, Nuckols J R, Ward M H, et al. An automated approach to mapping corn from Landsat imagery[J]. Computers And Electronics In Agriculture, 2004, 43(1): 43－54.

[13] Chang J, Hansen M C, Pittman K, et al. Corn and soybean mapping in the united states using MODIS time-series data sets[J]. Agronomy Journal, 2007, 99(6): 1654－1664.

[14] De Souza C H W, Mercante E, Johann J A, et al. Mapping and discrimination of soya bean and corn crops using spectro-temporal profiles of vegetation indices[J]. International Journal of Remote Sensing, 2015, 36(7): 1809－1824.

[15] Hao Pengyu, Zhan Yulin, Wang Li, et al. Feature selection of time series MODIS data for early crop classification using random forest: A case study in Kansas, USA[J]. Remote Sensing, 2015, 7(5): 5347－5369.

[16] Franch B, Vermote E F, Becker-Reshef I, et al. Improving the timeliness of winter wheat production forecast in the United States of America, Ukraine and China using MODIS data and NCAR growing degree day information[J]. Remote Sensing of Environment, 2015, 161: 131－148.

[17] Wu Zhuoting, Thenkabail P S, Rick M, et al. Seasonal cultivated and fallow cropland mapping using MODIS-based automated cropland classification algorithm[J]. Journal of Applied Remote Sensing, 2014, 8(1): 397－398.

[18] Sakamoto T, Wardlow B D, Gitelson A A, et al. A Two-Step Filtering approach for detecting maize and soybean phenology with time-series MODIS data[J]. Remote Sensing of Environment, 2010, 114(10): 2146－2159.

[19] Pittman K, Hansen M C, Becker-Reshef I, et al. Estimating global cropland extent with multi-year MODIS Data[J]. Remote Sensing, 2010, 2(7): 1844－1863.

[20] Ozdogan M. The spatial distribution of crop types from MODIS data: Temporal unmixing using independent component analysis[J]. Remote Sensing of Environment, 2010, 114(6): 1190－1204.

[21] Pan Yaozhong, Li Le, Zhang Jinshui, et al. Winter wheat area estimation from MODIS-EVI time series data using the crop proportion phenology index[J]. Remote Sensing of Environment, 2012, 119(3): 232－242.

[22] Damien A, Milton J, Dubreuil V, et al. Classification of MODIS EVI time series for crop mapping in the state of Mato Grosso, Brazil[J]. International Journal of Remote Sensing,

2011, 32(22): 7847－7871.
[23] Wardlow B D, Egbert S L, Kastens J H. Analysis of time-series MODIS 250 m vegetation index data for crop classification in the US Central Great Plains[J]. Remote Sensing of Environment, 2007, 108(3): 290－310.
[24] Wardlow B D, Egbert S L. Large-area crop mapping using time-series MODIS 250 m NDVI data: An assessment for the US Central Great Plains[J]. Remote Sensing of Environment, 2008, 112(3): 1096－1116.
[25] Breiman L. Random forests[J]. Machine Learning, 2001, 45(1): 5－32.
[26] 方匡南，吴见彬，朱建平，等. 随机森林方法研究综述[J]. 统计与信息论坛，2011,26(3)：32－38.
Fang Kuangnan, Wu Jianbin, Zhu Jianping, et al. A review of technologies on random forests[J]. Statistics & Information Forum, 2011, 26(3): 32－38. (in Chinese with English abstract)
[27] Ghosh A, Sharma R, Joshi P K. Random forest classification of urban landscape using Landsat archive and ancillary data: Combining seasonal maps with decision level fusion[J]. Applied Geography, 2014, 48(2): 31－41.
[28] 刘毅，杜培军，郑辉，等. 基于随机森林的国产小卫星遥感影像分类研究[J]. 测绘科学，2012，37(4)：198－200.
Liu Yi, Du Peijun, Zheng Hui, et al. Classification of China small satellite remote sensing image based on random forests[J]. Science of Surveying and Mapping, 2012, 37(4): 198－200. (in Chinese with English abstract)
[29] Liu H Q, Huete A. A feedback based modification of the NDVI to minimize canopy background and atmospheric noise[J]. IEEE Transactions on Geoscience And Remote Sensing, 1995, 33(2): 457－465.
[30] 刘勇洪，牛铮. 基于 MODIS 遥感数据的宏观土地覆盖特征分类方法与精度分析研究[J]. 遥感技术与应用，2004, 19(4)：217－224.
Liu Yonghong, Niu Zheng. Regional land cover image classification and accuracy evaluation using MODIS Data[J]. Remote Sensing Technology and Application, 2004, 19(4): 217－224. (in Chinese with English abstract)
[31] 田苗，王鹏新，严泰来，等. Kappa 系数的修正及在干旱预测精度及一致性评价中的应用[J]. 农业工程学报，2012, 28(24)：1－7.
Tian Miao, Wang Pengxin, Yan Tailai, et al. Adjustment of Kappa coefficient and its application in precision and agreement evaluation of drought forecasting models[J]. Transactions of the Chinese Society of Agricultural Engineering (Transactions of the CSAE), 2012, 28(24): 1－7. (in Chinese with English abstract)

Mapping corn and soybean cropped area with GF-1 WFV data

Huang Jianxi, Hou Yuzhuo, Su Wei, Liu Junming, Zhu Dehai

(*College of Information and Electrical Engineering, China Agricultural University, Beijing* 100083*, China*)

Abstract: Planting area and spatial distribution information of crops are vital for guiding agricultural production, taking effective management measurements, and monitoring crop growth conditions. Numerous crop classification algorithms have been developed with rapid development of different remote sensing data. However, distinguishing of corn and soybean cropping areas still remains a difficult challenge due to their similar growth calendar and spectral characteristics. In this study, we tried to identify corn and soybean cropping area using random forest (RF) classifier which has been proved to be an effective method in land cover classification based on multi-temporal GF-1 WFV (wide field of view) imagery. We selected Nenjiang County, Heilongjiang Province in China as the study area which was called the Town of Soybean. Seven GF-1 WFV time-series images (April 14th, May 20th, June 26th, July 16th, August 26th, September 4th, and September 29th), from which the key growth stages could be extracted and the effects of clouds could be avoided, were chosen to classify main crops. First, we conducted atmospheric and geometric corrections on multi-temporal GF-1 imagery. In order to improve the accuracy of distinguishing corn and soybean cropping area, the parameters of RF classifier were input, which included normalized difference vegetation index (NDVI), wide dynamic range vegetation index (WDRVI), enhanced vegetation index (EVI), and normalized difference water index (NDWI), and hundreds of field sample points were collected in the field survey. Also, it's necessary to evaluate the importance of different combination of these indices. The results showed that the combination of NDVI, WDRVI and NDWI achieved the best accuracy with the producer accuracy of 91.14% for soybean and 91.49% for corn, and with the user accuracy of 82.76% for soybean and 93.48% for corn. Then, the support vector machine (SVM) and maximum likelihood (ML) supervised classifiers were also used to map corn and soybean cropping areas; the classification results from the SVM and ML methods were compared with that from the RF approach with the Nenjiang Farm as the case study. The comparisons showed that the crop classification from the RF classifier had the higher accuracy than the others. Our results indicated that GF-1 data had particular advantages in mapping cropping area with its higher spatial and temporal resolutions, and could provide more effective remote sensing data during crop growth season. The temporal changes of main crops showed the best classifying date was September 29th when soybean has been harvested but corn hasn't, and their vegetation indices showed the maximum difference. The multi-temporal imagery contributed to the separation of different spectral feature curves of different crops in the growth stages when crops had similar temporal variation profiles, which helped to decrease the omission and commission errors of the resultant mapping. The results also showed that the extracted spectral information of water and construction land was very different from vegetation and could be easily masked. Comparing the SVM and ML classifiers with RF classifier, the results suggested that RF classifier could successfully distinguish corn and soybean, and its overall accuracy reached up to 84.82%. This study provides important reference for crop mapping in other agricultural regions.

Keywords: remote sensing; extraction; classification; random forest; soybean; corn