# 时空深度学习模型在玉米—大豆分类中的空间泛化能力分析

黄游缘[1]，林 娜[1]，范 莉[2]

（1. 重庆交通大学智慧城市学院，重庆 400074；2. 中国气象局气候资源经济转化重点开放实验室重庆市气象服务中心，重庆 401147）

**摘要：**[目的] 待补。[方法] 待补。[结果] 待补。[结论] 待补。

**关键词：**多时相遥感影像；时空深度学习；空间泛化；农作物识别

【中图分类号】P237　　【文献标志码】A　　【文章编号】1009-2307（20 ）0 -

# Spatiotemporal Deep Learning for Remote Sensing Identification of Corn and Soybean with Spatial Generalization

HUANG Youyuan[1], LIN Na[1], FAN Li[2]

(1. School of Smart City, Chongqing Jiaotong University, Chongqing 400074, China;
2. China Meteorological Administration Key Open Laboratory of Transforming Climate Resources to Economy, Chongqing Meteorological Service Center, Chongqing 401147, China)

Abstract: [Purposes] **TBD**. [Methods] **TBD**. [Findings] **TBD**.

Key words: multi-temporal remote sensing imagery; spatiotemporal deep learning; spatial generalization; crop identification

## 0 引言

## 1 研究区域与数据

### 1.1 研究区概况

4 个站点均位于美国中西部玉米带内，该区域以玉米和大豆种植为主，分别记为 A、B、C 和 D，自西向东排列顺序为 A、B、D、C。四站彼此相互独立，站点中心间距平均约 452 km，最大约 793 km；各站均为 76.8 km × 76.8 km 的正方形区域，边界沿等积投影的坐标轴方向延伸，与经纬线方向存在一定偏差。四站中心坐标依次为 A（西经 95.9085°、北纬 42.8746°）、B（西经 91.6892°、北纬 42.2382°）、C（西经 86.7671°、北纬 40.7431°）和 D（西经 89.2372°、北纬 40.1071°）。四站 2023 年地物分类图见图 1，子图采用相同的范围和显示比例，排列仅反映版面顺序，不表示站点间的实际方位。

图 1 中的数据来自美国农业部国家农业统计局（USDA NASS）发布的耕地数据层（Cropland Data Layer，CDL）。基于 2023 年 CDL 数据统计结果，4 个站点均以玉米和大豆为主要作物类型，两者面积之和均超过农作物总面积的 90%。本文将 CDL 原始类别重分类为玉米、大豆和其它地类 3 类，其中除玉米和大豆以外的农作物和非农作物地类均归并为其它地类。四站均以玉米和大豆为主要作物，但地物组成与景观格局存在差异。

玉米和大豆的物候信息来自美国农业部国家农业统计局发布的作物进度报告（Crop Progress Report，CPR）。结合该报告，本文以年积日（DOY）116–266 作为主要观测窗口，该窗口覆盖玉米和大豆的主要生育阶段。

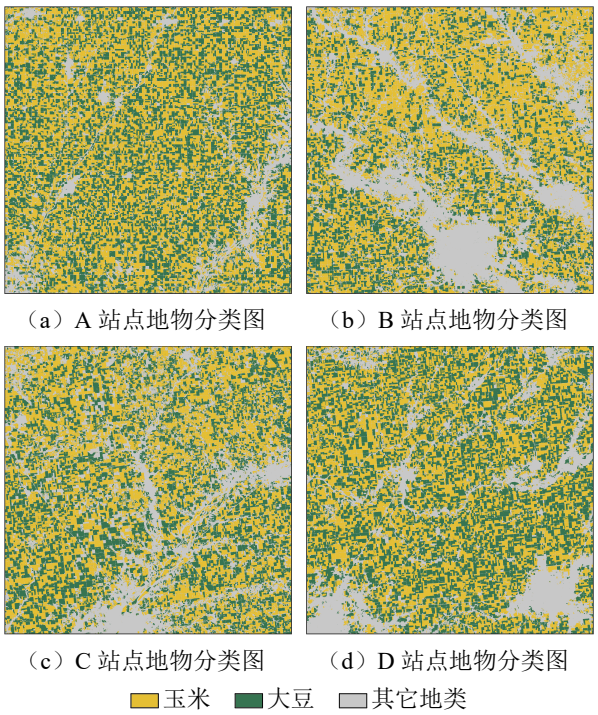


图 1 四个研究站点 2023 年地物分类图

**1.2** 数据获取与预处理

本文采用的多时相遥感数据源自美国国家航空航天局（NASA）地球数据科学系统提供的协同陆地卫星和哨兵 2 号数据（Harmonized Landsat and Sentinel-2，HLS）第 2 版。该产品通过对 Landsat-8/9 OLI 与 Sentinel-2 MSI 的观测影像进行辐射定标、大气校正、几何精校正以及网格重采样，实现了两类卫星数据的深度融合。本研究选取其空间分辨率为 30 m 的多时相地表反射率数据，包含蓝光、绿光、红光、近红外、短波红外 1 和短波红外 2 共 6 个核心波段作为深度学习模型的输入特征。

标签数据采用 USDA NASS CropScape 门户网站提供的 2023 年 CDL 产品。CDL 数据提供了美国本土逐像素的年度作物类型分类信息，在本研究中用于模型训练的真值标记与精度检验。研究对原始的 CDL 分类体系进行重分类，统一划分为玉米（Corn）、大豆（Soybean）和其它地类（Others）3 个目标类别。重分类后的标签数据在空间投影和分辨率上与对应的多时相 HLS 影像进行严格对齐。

在预处理阶段，首先对影像进行镶嵌、云掩膜和裁剪处理。随后，对时间序列采用时序线性插值方法补齐无效观测，并统一 4 个站点的时间跨度与时间间隔。最终，构建得到空间大小为 2560×2560 像素，时间分辨率为 5 天、包含 31 个时间步、空间分辨率为 30 m、光谱波段数为 6 的数据集。样本构建时，将多时相影像及其对应标签裁剪为 128 × 128 像素图块，相邻图块无重叠；在此基础上，最终每个站点每年获得 400 个样本用于后续模型训练与验证。

**1.3** 研究区空间特征

本文基于 2023 年 CDL 参考标签，从地物组成和景观格局两个方面比较 4 个站点的空间特征，为后续站内分类与跨站比较提供研究区背景。

1.3.1 地物组成

如图 2 所示，4 个站点均以玉米和大豆为主要地物，两者面积之和占各站总面积的 65.57%～82.16%。各站玉米面积占比为 39.97%～45.39%，大豆占比为 23.49%～36.77%，站点间大豆占比的变化幅度更大。A 站两种作物合计占比最高，其它地类仅占 17.84%；B 站大豆占比最低，其它地类占比达到 34.43%。因此，4 个站点具有相同的主要作物组成，但两种作物与其它地类的面积配置存在差别。

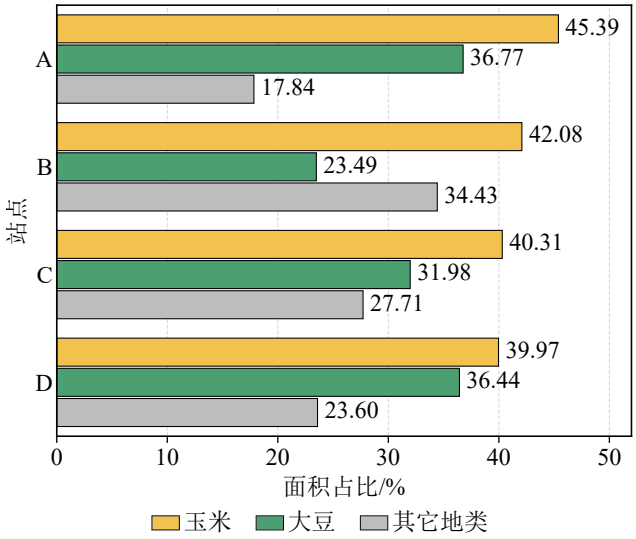



图 2 四个研究站点 2023 年地物面积占比

### 1.3.2 景观格局

在各站 2023 年 30 m 参考标签上，将 8 邻域相连的同类像元视为一个参考斑块，它不等同于实际农业田块。四站玉米和大豆均有大量单像元斑块，占各站相应作物斑块总数的 44.31%～54.64%，但仅占相应作物总面积的 0.23%～0.71%。为描述主要作物面积所在斑块的大小和轮廓复杂程度，斑块面积（AREA）与形状指数（SHAPE）采用参考像元面积加权中位数 [1]，即按指标值升序累计参考像元数，取首次达到该站该作物总像元数 50% 时的指标值。同类最近邻距离（ENN）按斑块等权计算中位数，每个完整参考斑块计一次；三项指标均保留全部斑块，并报告斑块数量与完整取值范围。

如表 1 所示，四站两种作物均具有较高的同类聚集程度，聚集度指数（AI）为 91.22%～93.92%，站点间数值接近。四站玉米的 AREA 面积加权中位数也较接近，为 116.91～130.95 ha；两种作物八组 ENN 斑块等权中位数均为 67.08 m。ENN 描述斑块与最近另一个同类斑块的距离，与 AI 所反映的同类聚集程度含义不同；中位数相同不表示完整距离分布相同。

在上述共同背景下，大豆斑块大小的站间变化更大，AREA 面积加权中位数为 63.27～114.39 ha。B 站玉米与大豆的斑块大小差别最突出，D 站两者最接近。C 站两种作物的 SHAPE 面积加权中位数和斑块密度（PD）均为四站最高，AI 相对最低，整站三类景观的边缘密度（ED）也最高，为 65.53 m/ha；但该站两种作物的 AREA 面积加权中位数均非最低，斑块数量多并不意味着主要作物面积集中于最小斑块。四站面积相同，斑块数量与 PD 成比例。这些共同特点与差异为后续从斑块大小、形状、聚集和邻近条件考察分类错误提供空间背景。

表 1 四个研究站点 2023 年作物斑块、类别与整站景观格局指标

| 站点 | 作物 | 斑块级 | | | | 类别级 | | 景观级 |
|---|---|---|---|---|---|---|---|---|
| | | AREA/ha | SHAPE | ENN/m | 斑块数 | PD/(个/100 ha) | AI/% | ED/(m/ha) |
| A | 玉米 | 116.91（0.09～455.40） | 1.63（1.00～5.58） | 67.08（60.00～729.93） | 15146 | 2.57 | 93.92 | 55.21 |
| | 大豆 | 92.43（0.09～348.21） | 1.58（1.00～5.41） | 67.08（60.00～930.00） | 14695 | 2.49 | 93.46 | |
| B | 玉米 | 130.95（0.09～731.52） | 1.88（1.00～5.59） | 67.08（60.00～2015.37） | 14460 | 2.45 | 93.25 | 54.47 |
| | 大豆 | 63.27（0.09～388.89） | 1.61（1.00～4.90） | 67.08（60.00～3886.24） | 16039 | 2.72 | 91.60 | |
| C | 玉米 | 127.44（0.09～2043.36） | 2.07（1.00～9.47） | 67.08（60.00～780.58） | 29837 | 5.06 | 91.88 | 65.53 |
| | 大豆 | 103.32（0.09～904.32） | 1.91（1.00～7.17） | 67.08（60.00～1218.24） | 27894 | 4.73 | 91.22 | |
| D | 玉米 | 121.86（0.09～1188.27） | 1.73（1.00～7.57） | 67.08（60.00～2206.17） | 16756 | 2.84 | 93.58 | 51.76 |
| | 大豆 | 114.39（0.09～1152.00） | 1.73（1.00～6.58） | 67.08（60.00～2323.98） | 14407 | 2.44 | 93.43 | |

注：AREA、SHAPE 为参考像元面积加权中位数，ENN 为斑块等权中位数；括号内均为全体斑块最小值～最大值。SHAPE 无量纲。ENN 按研究区内最近同类斑块的边界像元中心计算，最小可能值为 60 m，非田块间净空距离。PD 以整站面积为分母；ED 覆盖玉米、大豆及其它地类。

## 2 研究方法

### 2.1 时空深度学习模型

#### 2.1.1 U-TAE 模型

#### 2.1.2 3D U-Net 模型

#### 2.1.3 ConvGRU 模型

### 2.2 实验设计

本研究围绕玉米、大豆与其它地类三类目标，设计站内分类实验与跨站点空间泛化实验，以评估三种时空深度学习模型的分类能力与空间泛化性能。

#### 2.2.1 站内分类实验

站内实验中，每个站点用 2023 年多时相 HLS 影像和 CDL 标签构建 400 个互不重叠的图块样本，采用 5 折交叉验证训练和评估。400 个样本分为 5 个互不重叠的子集（折），每轮取其中 3 个子集训练、1 个子集验证（用于早停）、1 个子集测试。5 轮之后，每个样本恰好被测试一次，得到覆盖全站的交叉验证预测。

站内精度由 5 折测试的混淆矩阵汇总计算：将 5 个混淆矩阵逐元素相加，再由汇总混淆矩阵计算玉米 F1、大豆 F1 和 OA，得到基于全站预测的站内汇总精度，用作与跨站结果比较的基准。另计算每种模型在每个站点的 5 折测试 F1 均值与标准差，用于说明折间差异；该统计量不参与跨站比较。后文如无特别说明，站内精度均指汇总精度。

三种模型均用 PyTorch 实现，训练策略和超参数统一：优化器为 AdamW，损失函数为交叉熵，初始学习率 0.0001，批次大小 4，余弦退火学习率调度（$T_{\max}=50$，$\eta_{\min}=0.00005$），权重衰减 0.00005，梯度裁剪阈值 5.0，并采用早停（容忍 15 轮，最小改善量 0.0001）防止过拟合。训练时对每个图块做 0°、90°、180°、270° 四种旋转增强，每折有效训练样本由 240 扩展到 960。所有模型在同一硬件环境下训练。

#### 2.2.2 跨站点空间泛化实验

在跨站点泛化实验中，依次选取四个站点之一作为源站点，利用其站内实验训练所得的 5 个模型（每折一个），分别对其余三个目标站点的全部 400 个图块逐块推理。每条迁移路径得到 5 次完整预测，每次将 400 个图块的混淆矩阵汇总后计算指标，再对 5 次结果取均值与标准差。迁移过程中不微调、不集成，以比较三种模型结构的分类性能与空间泛化性能。4 个站点轮换作为源站点，共 12 条有向迁移路径，3 种模型合计 36 个模型—路径组合、180 次完整预测。

为衡量跨站应用的精度与目标站当地训练精度之间的差距，本文以同一模型在目标站点的站内汇总 F1 为基准，计算 F1 差值。以玉米为例：

$$\Delta F1_{\text{玉米}} = F1_{\text{目标站站内玉米}} - \overline{F1}_{\text{跨站玉米}} \qquad (1)$$

式中，$F1_{\text{目标站站内玉米}}$ 为该模型在目标站点的站内汇总玉米 F1，$\overline{F1}_{\text{跨站玉米}}$ 为源站点模型在目标站点的跨站玉米 F1 五次均值，计算时二者取值均为 0～1。$\Delta F1_{\text{玉米}}$ 为二者直接相减的差值，正值表示跨站精度低于目标站点的站内精度，负值表示跨站精度高于站内精度。大豆的 F1 差值 $\Delta F1_{\text{大豆}}$ 同理计算。F1 及

其标准差以百分数表示，F1 差值以百分点表示，均将原尺度数值乘以 100 后保留两位小数；计算和比较使用未舍入值，差值不除以站内基准。

**2.3** 精度评价指标

模型精度由预测结果与像元级真实标签构成的混淆矩阵计算。对玉米、大豆、其它地类三类，混淆矩阵元素 $C_{ij}$ 表示真实类别为 $i$、预测为 $j$ 的像元数。类别 $i$ 的精确率 $P_i$ 为

$$P_i = \frac{C_{ii}}{\sum_j C_{ji}} \tag{2}$$

召回率 $R_i$ 为

$$R_i = \frac{C_{ii}}{\sum_j C_{ij}} \tag{3}$$

F1 为二者的调和平均：

$$F1_i = \frac{2P_iR_i}{P_i + R_i} \tag{4}$$

总体精度（OA）为

$$\mathrm{OA} = \frac{\sum_i C_{ii}}{\sum_{i,j} C_{ij}} \tag{5}$$

本研究关注玉米和大豆的识别与泛化能力，因此分别报告玉米 F1（$F1_{玉米}$）和大豆 F1（$F1_{大豆}$）作为主要指标，OA 作为总体参考。

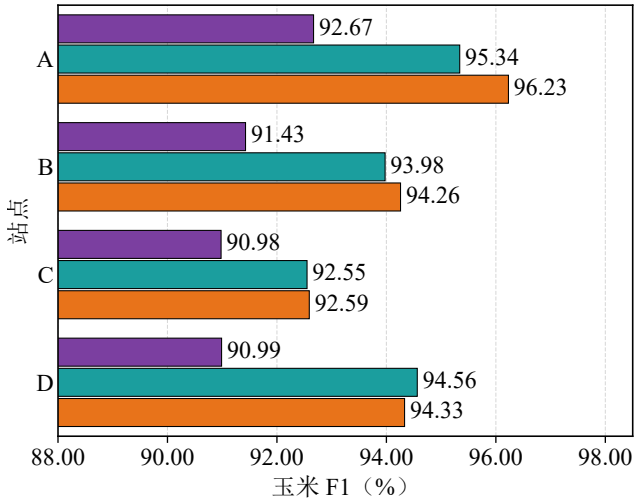
**2.4** 硬件和软件配置

模型在 Linux 工作站（Ubuntu 22.04）上训练，配置为 Intel Xeon Gold 6430 处理器（2.1 GHz，32 核）、120 GB 内存和 1 块 NVIDIA GeForce RTX 4090 显卡（24 GB 显存），深度学习框架为 PyTorch。

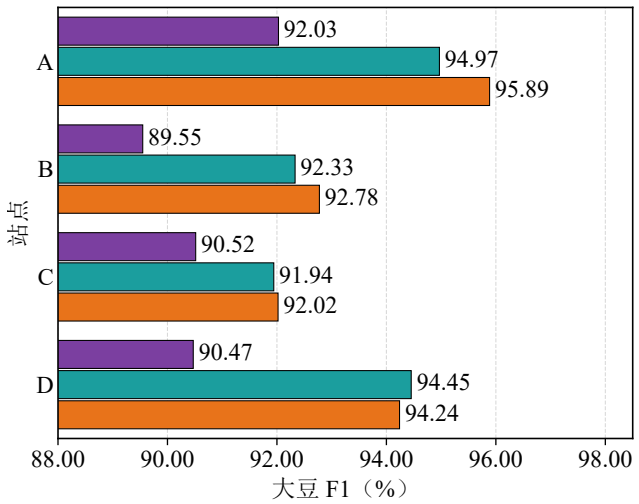
## 3 实验结果与分析

**3.1** 模型站内分类性能

如图 3 所示，三种模型在四个站点的站内玉米 F1 为 90.98%～96.23%，大豆 F1 为 89.55%～95.89%。三种模型的分类表现呈现出两点共性：在四个站点上，玉米 F1 均高于大豆 F1，差值均小于 2.00 个百分点；跨站点比较，各模型的玉米和大豆 F1 均在 A 站点取得各自最高值。五折交叉验证中，同一数据集不同划分下的每折独立训练，12 组实验（3 种模型 ×4 个站点）的玉米和大豆 F1 折间标准差均小于 1.00%。




（a）四站点玉米分类精度




（b）四站点大豆分类精度

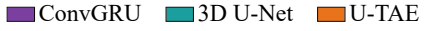



图 3 三种模型在四个站点的站内玉米和大豆分类精度

三种模型之间的差异主要体现在 ConvGRU 与另两种模型之间。U-TAE 和 3D U-Net 在各站点的玉米和大豆 F1 均高于 ConvGRU，而二者之间差值均小于 1.00 个百分点，互有高低：U-TAE 在 A、B 两个站点略优，3D U-Net 在 D 站点略优，C 站点 U-TAE 的玉米和大豆 F1 分别高出 0.04 和 0.08 个百分点。ConvGRU 与前两者的差距因站点而异：两种作物在 C 站点为 1.43～1.61 个百分点，在 D 站点为 3.34～3.98 个百分点。图 4 以差距较大的 D 站点为例对比了三种模型的站内交叉验证分类结果：在选中局部区域中，ConvGRU 的玉米和大豆像元错误率为 12.1%，高于 3D U-Net（5.8%）和 U-TAE（4.8%）。

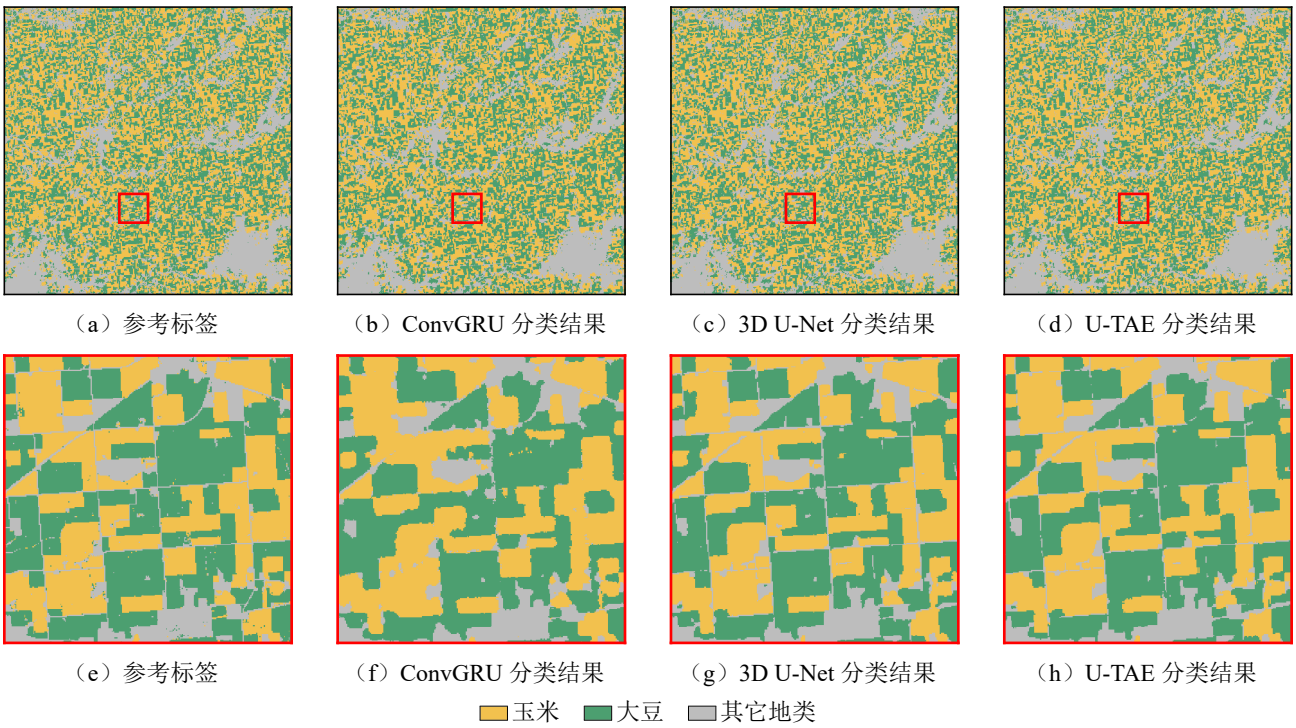



图 4 D 站点三种模型站内交叉验证分类结果（上：全站，红框为局部窗口；下：局部窗口放大）

**3.2** 模型跨站分类性能与泛化退化

如表 2 所示，源站模型不经微调直接用于目标站后，36 个模型—路径组合的玉米和大豆跨站 F1 均低于同一模型在目标站的站内汇总 F1。跨站玉米 F1 为 85.68%～92.92%，大豆 F1 为 83.08%～92.15%，每项为五次完整目标站预测的均值。按目标站对 3 条路径取平均，三种模型的玉米和大豆跨站 F1 均在以 A 站点为目标站时最高，与站内结果中 A 站点精度最高相对应；玉米跨站 F1 则均在以 C 站点为目标站时最低，大豆跨站 F1 的最低目标站则不一致。

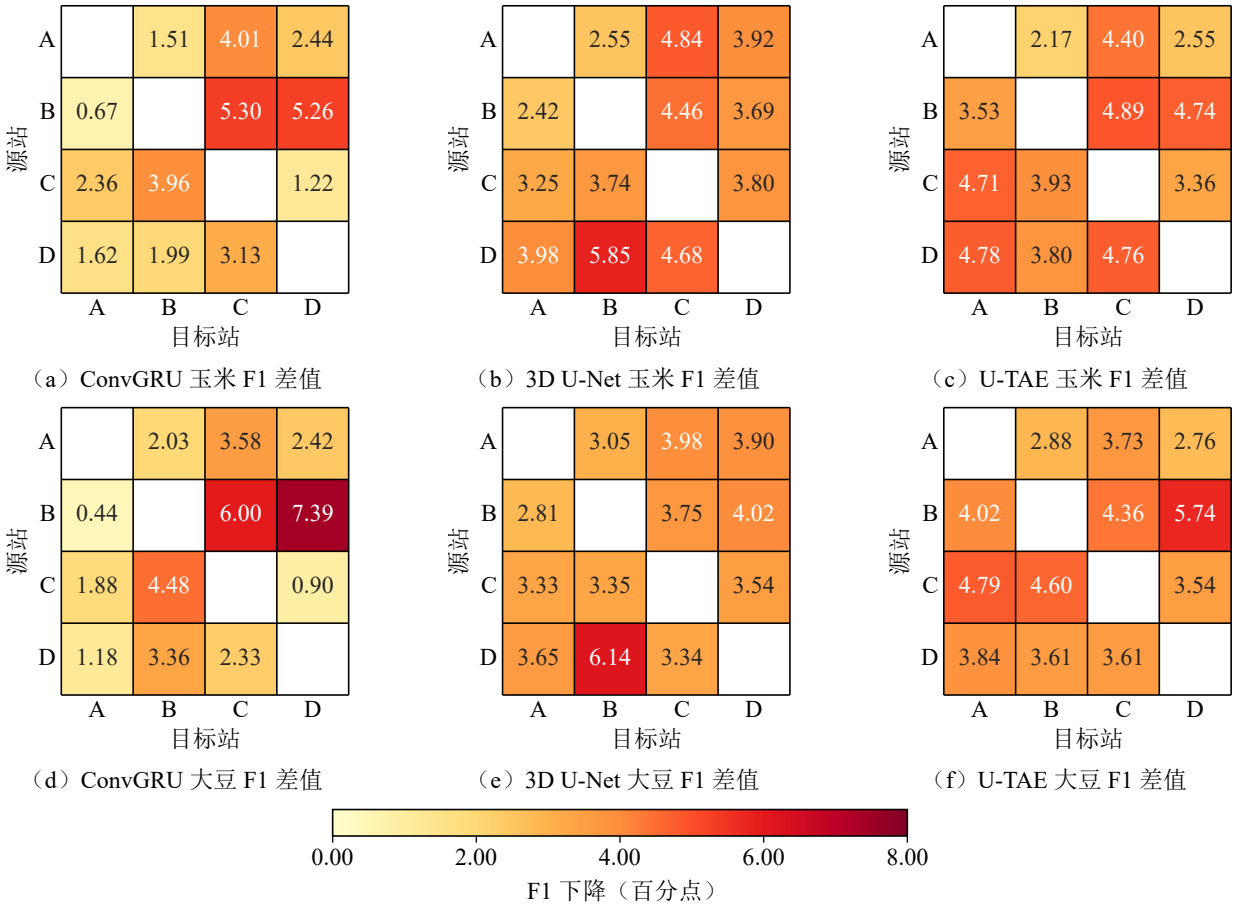
按 12 条路径取算术平均，ConvGRU 的跨站 F1 均值最低，但平均 F1 差值最小：其跨站玉米和大豆 F1 分别为 88.73% 和 87.64%，比 3D U-Net 和 U-TAE 低 1.45～2.13 个百分点（后两者两种作物的均值为 89.69%～90.39%）；而玉米和大豆平均 F1 差值分别为 2.79 和 3.00 个百分点，小于 3D U-Net 和 U-TAE（3.74～3.97 个百分点）。跨站 F1 比较的是模型在目标站的实际分类精度，F1 差值衡量的则是跨站 F1 与同一模型在目标站站内汇总 F1 之间的差距。因此，F1 差值较小不代表跨站绝对精度更高，评价模型的跨站表现需要同时考察这两个指标。

如图 5 所示，F1 差值随源—目标组合而变化，且三种模型的变化并不一致。即使目标站相同，F1 差值也会随源站不同而改变：以 D 站点为目标站时，ConvGRU 的大豆 F1 差值在源站为 C 时为 0.90 个百分点，源站为 B 时为 7.39 个百分点；这两种源站下五次预测对应的 F1 差值分别为 0.77～0.99 和 3.29～10.81 个百分点，源站为 B 时的每一次结果均高于源站为 C 时，但五次之间的波动也更大。在 B、D 两个站点之间，两个方向上的 F1 差值大小关系也因模型而异：ConvGRU 的玉米和大豆 F1 差值均为 B→D 方向较大，3D U-Net 则均为 D→B 方向较大；以大豆为例，ConvGRU 在 B→D 和 D→B 路径上分别为 7.39 和 3.36 个百分点，3D U-Net 分别为 4.02 和 6.14 个百分点。上述方向差异基于五次预测的均值，仅反映这一站点对上的表现，不代表普遍的迁移规律。这些差异与站点空间特征的对应关系，将在后文结合地物组成与景观结构分析。

表 2 三种模型在 12 条迁移路径上的跨站玉米和大豆 F1

| 迁移路径 | ConvGRU | | 3D U-Net | | U-TAE | |
|---|---|---|---|---|---|---|
| | 玉米 F1（%） | 大豆 F1（%） | 玉米 F1（%） | 大豆 F1（%） | 玉米 F1（%） | 大豆 F1（%） |
| A→B | 89.91 ± 0.11 | 87.52 ± 0.40 | 91.43 ± 0.39 | 89.28 ± 0.40 | 92.09 ± 0.26 | 89.90 ± 0.38 |
| A→C | 86.97 ± 0.59 | 86.94 ± 1.20 | 87.71 ± 0.59 | 87.96 ± 0.34 | 88.20 ± 0.61 | 88.29 ± 0.69 |
| A→D | 88.54 ± 0.67 | 88.05 ± 1.16 | 90.64 ± 0.53 | 90.56 ± 0.45 | 91.78 ± 0.43 | 91.48 ± 0.41 |
| B→A | 92.00 ± 0.18 | 91.59 ± 0.13 | 92.92 ± 0.59 | 92.15 ± 0.44 | 92.70 ± 0.25 | 91.87 ± 0.31 |
| B→C | 85.68 ± 0.95 | 84.52 ± 1.63 | 88.09 ± 0.55 | 88.20 ± 0.81 | 87.70 ± 0.58 | 87.66 ± 0.84 |
| B→D | 85.73 ± 1.67 | 83.08 ± 2.70 | 90.87 ± 0.33 | 90.43 ± 0.41 | 89.59 ± 1.41 | 88.50 ± 2.20 |
| C→A | 90.31 ± 0.59 | 90.15 ± 0.49 | 92.09 ± 0.40 | 91.64 ± 0.43 | 91.52 ± 0.61 | 91.09 ± 0.39 |
| C→B | 87.47 ± 1.05 | 85.06 ± 0.96 | 90.23 ± 1.00 | 88.98 ± 0.88 | 90.33 ± 0.62 | 88.18 ± 0.52 |
| C→D | 89.77 ± 0.29 | 89.57 ± 0.08 | 90.77 ± 0.85 | 90.91 ± 0.17 | 90.98 ± 0.39 | 90.70 ± 0.48 |
| D→A | 91.05 ± 0.24 | 90.85 ± 0.52 | 91.36 ± 0.68 | 91.32 ± 0.68 | 91.45 ± 0.26 | 92.04 ± 0.37 |
| D→B | 89.44 ± 0.24 | 86.19 ± 0.46 | 88.13 ± 1.24 | 86.19 ± 1.91 | 90.45 ± 0.45 | 89.17 ± 0.98 |
| D→C | 87.85 ± 0.30 | 88.19 ± 0.54 | 87.88 ± 0.71 | 88.60 ± 0.83 | 87.83 ± 0.89 | 88.41 ± 0.84 |
| 平均 | 88.73 | 87.64 | 90.18 | 89.69 | 90.39 | 89.77 |

注：箭头左侧为源站，右侧为目标站。各路径单元格为均值 ± 标准差，二者均按百分数尺度显示；源站 5 个折模型分别预测目标站全部 400 个图块后计算 F1，标准差采用样本标准差（分母为 4），未进行微调和模型集成。“平均”行仅列 12 条迁移路径 F1 均值的算术平均。




（a）ConvGRU 玉米 F1 差值　（b）3D U-Net 玉米 F1 差值　（c）U-TAE 玉米 F1 差值

（d）ConvGRU 大豆 F1 差值　（e）3D U-Net 大豆 F1 差值　（f）U-TAE 大豆 F1 差值

图 5 不同源—目标区域组合下三种模型的玉米和大豆 F1 差值（单位：百分点；行为源站，列为目标站，对角线不适用；同模型目标站站内 F1 减跨站五次均值，六幅子图共用色标）

**3.3** 模型跨站泛化差异的空间解释

## 4 结论

## 参考文献：

[1] Kevin McGarigal, Samuel A. Cushman, and Eduard Ene. FRAGSTATS v4: Spatial pattern analysis program for categorical maps. URL `https://www.fragstats.org`.